# Université de Rouen Normandie

URF Droit, Science Economiques et Gestion


**Master Monnaie Banque Finance Assurance parcours EGRF**
Année universitaire 2025-2026

## MEMOIRE DE RECHERCHE

Présenté en vue de l'obtention du diplôme de Master Monnaie Banque Finance Assurance parcours Economie et Gestion des Risques Financiers

# Data analytics et modélisation des risques opérationnels : conception d'un outil d'aide à la détection et au pilotage des risques.


Réalisé par :
ABIKANLOU Hamed Adissa Oloukorédé

Sous la direction de :

Mme Hélène INTRATOR, MCF


Rouen, le 25 Aout 2026

# AVERTISSEMENT

**Déclaration sur l'Honneur**

Je, soussigné(e) ABIKANLOU Hamed Adissa Oloukorédé étudiant(e) en Master 2 Monnaie Banque Finance Assurance parcours Economie et Gestions de Risque Financiers, rédigeant un mémoire sous la direction de Mme Hélène INTRATOR, MCF à l'Université de Rouen, certifie que ce document est le fruit d'un travail original et que toutes les sources utilisées ont été clairement indiquées.

Je certifie de plus que je n'ai ni copié ni utilisé des idées, des formulations ou tout autre document tirés d'un ouvrage, article ou mémoire ou projet, en version imprimée ou élec tronique, sans mentionner précisément leur origine et que les citations sont expressément signalées entre guillemets.

Le non-respect de ces dispositions me rend passible de poursuites devant la section disci plinaire de l'Université et les tribunaux de la République française pour plagiat universitaire.

Fait à Rouen le 24/08/2026 Signature

# CERTIFICATION

Nous certifions que le présent mémoire a été réalisé par son auteur. Il est arrivé à terme et peut être soutenu devant un jury.

Rouen :.....

Le maitre mémoire

**Mme Hélène INTRATOR, MCF**

# DÉDICACES

Je dédie ce mémoire :
À mon mentor, M. BECQUE-LEGRAND Maxime, pour son encadrement, ses conseils et son accompagnement tout au long de ces derniers mois ;
À ma directrice de mémoire, Mme. Hélène INTRATOR, pour son soutien dans la rédaction de ce document ;
À mon frère, AGAI Ulrich, pour ses encouragements et sa présence réconfortante ;
À mes amis AHOUETOGNON Martin, ADJIBOTTCHA Henoch,pour leur soutien et leur motivation sans faille.

# REMERCIEMENTS

Nous adressons nos sincères remerciements à l'endroit de :

- Monsieur Cyril DELL'EVA, Responsable du Master 2 Monnaie, Banque, Finance, Assurance, parcours Économie et Gestion des Risques Financiers, pour son encadre ment et son engagement dans la formation des étudiants ;
- Madame Hélène INTRATOR, notre directeur de mémoire, pour sa disponibilité, ses conseils et son accompagnement tout au long de la réalisation de ce travail ;
- Tout le personnel enseignant de l'UFR Droit, Économie, Science Politique de l'Uni versité de Rouen Normandie, pour la qualité de la formation transmise ;
- Tous les enseignants du Master Monnaie, Banque, Finance, Assurance, parcours Économie et Gestion des Risques Financiers, pour la qualité des enseignements dispensés et les connaissances acquises tout au long de notre formation ;
- Tous les professionnels intervenant dans le cadre de la formation, pour leurs expé riences, leurs conseils et leur contribution à notre formation académique et profes sionnelle ;
- Tous nos camarades de la promotion du Master 2 MBFA– Économie et Gestion des Risques Financiers, pour leur esprit de convivialité, de solidarité et de fraternité ;

Enfin, nous remercions nos parents et amis, ainsi que tous ceux qui, de près ou de loin, ont contribué à l'élaboration de ce mémoire

# SIGLES ET ABRÉVIATIONS

| | |
|---|---|
| ADF | Augmented Dickey-Fuller (test de Dickey-Fuller augmenté) |
| AMA | Advanced Measurement Approach(es) |
| AUC | Area Under the Curve |
| BIA | Basic Indicator Approach |
| CNY | Chinese Yuan (Renminbi) |
| EGRF | Économie et Gestion des Risques Financiers |
| IC | Intervalle de Confiance |
| LDA | Loss Distribution Approach |
| MAE | Mean Absolute Error |
| MBFA | Monnaie Banque Finance Assurance |
| MCF | Maître de Conférences |
| NLP | Natural Language Processing |
| OR | Odds Ratio |
| ORX | Operational Riskdata eXchange Association |
| P-COLD | Public Chinese Operational Loss Database |
| PNB | Produit Net Bancaire |
| RCAP | Regulatory Consistency Assessment Programme |
| RMSE | Root Mean Square Error |
| ROC | Receiver Operating Characteristic |
| SHAP | SHapley Additive exPlanations |
| SMA | Standardised Measurement Approach |
| TSA | The Standardised Approach |
| UFR | Unité de Formation et de Recherche |
| VaR | Value at Risk |

# SOMMAIRE

**LISTE DES FIGURES** viii

**LISTE DES TABLEAUX** ix

**RÉSUMÉ** x

**ABSTRACT** xi

**INTRODUCTION GÉNÉRALE** 1

0.0.1 Contexte . . . 1

0.0.2 Problématique . . . 1

0.0.3 Intérêt de l'étude . . . 2

0.0.4 Objectifs et hypothèses . . . 2

0.0.5 Organisation du travail . . . 3

**1 CADRE THÉORIQUE DE L'ÉTUDE** 4

1.1 Revue de littérature . . . 4

1.1.1 Le risque opérationnel (définitions et Importances) . . . 4

1.1.2 Les différentes catégories du risque opérationnel. . . . 6

1.1.3 Évolution des méthodes de mesure de risques opérationnels de Bâle . . . 6

1.1.4 Data analytics et machine learning appliqués au risque . . . 8

1.1.5 Positionnement de la recherche . . . 10

**2 CADRE MÉTHODOLOGIQUE DE L'ÉTUDE** 11

2.1 Population d'étude et sources des données . . . 11

2.1.1 Population d'étude . . . 11

2.1.2 Source des données . . . 11

2.1.3 Apurement et prétraitement des données . . . 12

2.1.4 Présentation des variables de l'étude . . . 13

2.2 Construction des pertes logarithmique . . . 13

2.3 Analyse exploratoire et tests statistiques préalables . . . 14

2.3.1 Analyse descriptive . . . . . 14
2.3.2 Analyse de stationnarité et tests statistiques . . . . . 14
2.3.3 Modèle de régression logistique multinomiale et son estimation . . . . . 14
2.3.4 Modèle Random Forest . . . . . 16
2.3.5 Modèle Gradient Boosting . . . . . 16
2.3.6 La méthode SHAP . . . . . 18

**3 PRÉSENTATION DES RÉSULTATS 19**
3.1 Apurement et prétraitement des données . . . . . 19
3.2 Analyse exploratoire et tests statistiques préalables . . . . . 19
3.2.1 Analyse descriptive . . . . . 19
3.2.2 Analyse de la stationnarité et tests statistiques . . . . . 21
3.2.3 Modèle de régression logistique multinomiale et son estimation . . . . . 22
3.2.4 Modèle Random Forest . . . . . 26
3.2.5 Modèle Gradient Boosting . . . . . 27
3.2.6 Test de robustesse : contrôle du biais temporel et de la non stationnarité . . 30
3.2.7 Interprétabilité SHAP . . . . . 32

**4 DISCUSSION DES RÉSULTATS 36**
4.1 Synthèse des résultats et validation des hypothèses . . . . . 36
4.1.1 Synthèse des résultats . . . . . 36
4.1.2 Validation des hypothèses . . . . . 36
4.2 suggestions . . . . . 37
4.3 Les limites . . . . . 37

**CONCLUSION GÉNÉRALE 39**

**Références 39**

**Annexes A**

**Table des matières D**

# LISTE DES FIGURES

3.1 Distribution des pertes : brute vs logarithmique . . . . . 20
3.2 Répartition empilée des événements par catégories baloise et par année . . 21
3.3 Évolution annuelle de la fréquence et de la sévérité moyenne (logloss) . . . 22
3.4 Matrice de confusion du modèle logit . . . . . 25
3.5 Courbe ROC du modèle logit . . . . . 25
3.6 Matrice de Confusion et Courbe ROC du modèle Random Fores . . . . . 26
3.7 Importance des varibables . . . . . 27
3.8 Matrice de Confusion et Courbe ROC du modèle Gradient Boosting . . . . 28
3.9 Importance des variables . . . . . 28
3.10 Valeurs observées vs prédites et distributions des résidus . . . . . 29
3.11 l'importance relative de chaque variable . . . . . 30
3.12 comparaison de l'accuracy . . . . . 31
3.13 comparaison AUC /Pseudo R2 . . . . . 32
3.14 Importance globale des variables (SHAP) . . . . . 33
3.15 Distribution des SHAP (Volet classification) . . . . . 33
3.16 Décomposition d'une prédiction individuelle . . . . . 34
3.17 Importance globale des variables SHAP (volet sévérité) . . . . . 35

# LISTE DES TABLEAUX

2.1 Description des variables de la base de données . . . . . 13

3.1 Répartition et caractérisation des évènements de la base P-COLD . . . . . 19
3.2 Indicateurs de tendance . . . . . 20
3.3 Résultats des tests ADF . . . . . 22
3.4 Résultat du modèle logit . . . . . 23
3.5 Résultat du modèle logit . . . . . 24
3.6 Indicateurs de performance . . . . . 26
3.7 Indicateurs de performance du modèle . . . . . 28
3.8 Indicateurs de performance de régression . . . . . 29
3.9 Comparaison des performances avec et sans variable de contrôle temporelle 31

4.1 Statistiques descriptives du montant des pertes (en 10 000 CNY) . . . . . A
4.2 Résultats du test ADF sur les séries annuelles (1999-2019) . . . . . A
4.3 Dictionnaire des variables de la base P-COLD . . . . . B
4.4 Répartition croisée des événements par type de risque et ligne métier ($N = 3\,723$) . . . . . C

# RÉSUMÉ

Le risque opérationnel occupe une place délicate au sein de la réglementation bancaire. Contrairement au risque de crédit ou de marché, il résiste à toute mesure pleinement satisfaisante. En 2017, le Comité de Bâle a opté pour une méthode unique, l'Approche de mesure standardisée (SMA), remplaçant les anciennes approches BIA, TSA et AMA. Si elle a permis d'assurer la comparabilité entre les banques, cela s'est fait au prix de certains inconvénients. Briceño (2025) démontre que la SMA génère des exigences de fonds propres fluctuant d'une année à l'autre sans changement réel du profil de risque, pénalise paradoxalement les institutions réparties sur plusieurs entités et ne laisse aucune place à des facteurs aussi cruciaux que la qualité des contrôles internes. Sur ces trois points, l'ancienne approche de modélisation de la distribution des pertes (LDA) se montrait plus performante, bien que plus complexe et coûteuse à mettre en œuvre.

Parallèlement, l'apprentissage automatique machine learning a fait son apparition dans la gestion des risques bancaires, mais le plus souvent de manière fragmentée détectant une fraude ici, signalant une anomalie là sans jamais véritablement s'intégrer dans un processus cohérent de pilotage des risques à l'échelle de l'institution.

C'est ce constat qui constitue le point de départ de cette thèse. Il s'agit de concevoir un outil qui conserve la rigueur statistique de la LDA, y adjoint la puissance prédictive de l'apprentissage automatique (arbres de décision, forêts aléatoires) pour la détection d'anomalies, et intègre le tout dans un module de reporting conçu pour le pilotage opérationnel. Le prototype, développé sous Python et POWER BI, comprend un volet de modélisation fréquence-sévérité couplé à une simulation de Monte Carlo pour estimer la VaR opérationnelle et l'Expected Shortfall. Il sera testé sur des données simulées ou réelles afin de vérifier si cette approche permet effectivement de combler les lacunes de la SMA.

**Mots-clés** : risque opérationnel, Bâle III/IV, SMA, Loss Distribution Approach, VaR opérationnelle, machine learning, analyse de données, pilotage des risques.

# ABSTRACT

Operational risk occupies a challenging position within banking regulation. Unlike credit or market risk, it defies fully satisfactory measurement. In 2017, the Basel Committee adopted a single method the Standardized Measurement Approach (SMA) to replace the earlier BIA, TSA, and AMA approaches. While this ensured comparability across banks, it came at a cost : Briceño (2025) demonstrates that the SMA generates capital requirements that fluctuate from year to year without any actual change in the risk profile, paradoxically penalizes institutions spread across multiple entities, and leaves no room for crucial factors such as the quality of internal controls. On these three points, the older Loss Distribution Approach (LDA) performed better, despite being more complex and costly to implement.

At the same time, machine learning has emerged in banking risk management, yet often in a fragmented manner detecting fraud here, flagging an anomaly there without ever truly integrating into a coherent, institution-wide risk management process.

This observation serves as the starting point for this thesis.The aim is to design a tool that retains the statistical rigor of the LDA, incorporates the predictive power of machine learning (decision trees, random forests) for anomaly detection, and integrates everything into a reporting module designed for operational management. The prototype, developed in Python and Power BI, includes a frequency-severity modeling component coupled with a Monte Carlo simulation to estimate operational Value-at-Risk (VaR) and Expected Shortfall. It will be tested using simulated or real data to verify whether this approach effectively addresses the shortcomings of the SMA.

**Keywords** : operational risk, Basel III/IV, SMA, Loss Distribution Approach, operational VaR, machine learning, data analysis, risk management.

# INTRODUCTION GÉNÉRALE

### 0.0.1. Contexte

Le risque opérationnel a la particularité d'être considéré comme un risque à part dans le cadre des risques bancaires. Si le risque de crédit ou le risque de marché sont pour leur part des risques dont la dimension quantitative et la capacité à faire l'objet d'une modélisation d'ores et déjà relativement stabilisée, permet d'envisager un cadre réglementaire, ce n'est pas le cas du risque opérationnel. Ce risque, qui est celui qu'a retenu le Comité de Bâle comme étant le risque de pertes qui peuvent résulter de désordre ou dysfonctionnements de processus internes, de personnes, de systèmes, d'évènements externes peut « être défini comme tout type de risque lié à l'activité des entreprises qui n'est pas un risque de crédit ou de marché ; il est à ce point indifférencié qu'il ne permet pas de devenir mesurable (Nouy, 2006)[Nouy, 2006] ». Or, c'est bel et bien cette agrégation de risques différents qui complique l'identification précise du risque opérationnel (Nouy, 2006)[Nouy, 2006], d'autant plus que les événements extrêmes et générateurs de pertes alors particulièrement lourdes sont ceux qui sont les moins fréquemment rencontrés.

Cette problématique n'a cessé de croître dans l'agenda règlementaire depuis les accords de Bâle II. L'état des lieux des méthodes de mesure, de l'approche indicateur de base aux approches par mesure avancée fondées sur la Loss Distribution Approach (Frachot, Georges & Roncalli, 2001)[Frachot et al., 2001], est révélateur d'une volonté perpétuelle d'amélioration de l'adéquation entre d'une part le profil de risque effectif des établissements et d'autre part les besoins en fonds propres réglementaires exigés. Au demeurant, la méthode standard (SMA) récemment introduite par le Comité de Bâle ne fait pas consensus. Briceño (2025)[Briceño, 2025] la montre instable, super-additive et incapable d'intégrer les facteurs qualitatifs, ce qui redynamise la recherche de méthodes alternatives

Dans le cadre délimité, l'essor de l'apprentissage automatique pour la gestion du risque bancaire ne prend véritablement sens (Heß et Damásio, 2025)[Heß and Damásio, 2025] que dans le champ de la détection de la fraude, où son utilisation est déjà bien avancée (George, Alam et Hasan, 2025)[George et al., 2025], alors même qu'il apparaît aujourd'hui comme prometteur dans tout le champ du risque opérationnel classification automatique des typologies d'événements, prévision de l'intensité des pertes et identification des déterminants des facteurs de risque tandis que son introduction s'enlise avec la question de la tension entre performance et explicabilité des modèles (Černevičienė et Kabašinskas, 2024)[Černevičienė and Kabašinskas, 2024].

### 0.0.2. Problématique

Le machine learning promet ainsi de dépasser la seule détection de fraude pour couvrir l'ensemble du champ du risque opérationnel, classification automatique des typologies

d'événements, prévision de l'intensité des pertes, identification des déterminants du risque. Cette promesse se heurte cependant à deux difficultés récurrentes, identifiées dans la littérature. D'une part, le déséquilibre structurel des classes.Les événements les plus coûteux à traiter sont de surcroît statistiquement les plus rares, et donc les moins fréquentés au vrai sens et, par suite, pénalisent l'apprentissage des modèles traditionnels. Et d'autre part, la tension existante entre performance prédictive et explicabilité.Les modèles les plus performants étant également les moins transparents (et cette opacité des décisions prises automatiquement et leur intelligibilité étant devenue une exigence essentielle de la réglementation).

La question se pose alors de savoir dans quelle mesure recourir aux techniques de machine learning peut mieux détecter et caractériser le risque opérationnel bancaire, par rapport à une approche économétrique traditionnelle, tout en maintenant un niveau d'interprétabilité en phase avec les exigences de gouvernance du risque.

### 0.0.3. Intérêt de l'étude

Ce mémoire présente un double intérêt. Sur le plan académique, il dépasse le champ d'application de la seule détection de fraude (au sein duquel se concentre la majorité de la littérature existante) et embrasse l'ensemble des catégories de risque opérationnel selon Bâle tout en liant de manière explicite la rigueur actuarielle et le machine learning (et donc non avant tout).Sur le plan pratique, il propose une démarche à la fois reproductible et transparente, susceptible d'éclairer les équipes de gestion des risques par ligne métier sur les facteurs les plus déterminants du risque opérationnel alors même que la justification documentée des décisions automatisées devient la règle réglementaire.

### 0.0.4. Objectifs et hypothèses

Dans le cadre de cette étude, l'objectif général consiste dans la comparaison de trois approches de modélisation du risque opérationnel, à savoir un modèle économétrique traditionnel, et deux modèles de machine learning, et ce, en comparant leurs performances respectives, la stabilité des résultats obtenus tout en s'assurant de leur capacité à restituer une architecture fréquence/sévérité semblable à celle de la LDA. Ce but général est décliné en trois objectifs spécifiques :

- Comparer, dans le cadre de la classification des événements de perte opérationnelle, la capacité prédictive du modèle logit à celle du Random Forest et du Gradient Boosting,
- Vérifier la stabilité des déterminants du risque identifiés, en vérifiant notamment le risque d'une éventuelle non-stationnarité temporelle,
- Evaluer la pertinence d'une architecture de modélisation distinguant la fréquence et

la sévérité des pertes, comme cela apparaît dans la Loss Distribution Approach.

Chacun de ces objectifs a pour corollaire une hypothèse empirique que nous testerons dans la partie empirique de notre mémoire :

**H1 :** les modèles non paramétriques (Random Forest, Gradient Boosting) prédisent mieux que le logit mais sont moins interprétables ;

**H2 :** les déterminants de la fraude (ligne métier, montant de la perte) sont stables quel que soit le modèle

**H3 :**Les facteurs qui expliquent la sévérité d'une perte diffèrent de ceux qui expliquent sa fréquence, ce qui justifie une modélisation séparée des deux, à l'image de la LDA.

### 0.0.5. Organisation du travail

Pour répondre à ces objectifs, ce mémoire s'appuie sur la base de données P-COLD (Zhu, Chang et Li, 2024)[Zhu et al., 2024], qui recense 3 725 événements de perte opérationnelle survenus dans le secteur bancaire chinois entre 1986 et 2023. Le travail s'organise en deux grandes parties. La première propose une revue de la littérature portant sur la définition et la typologie du risque opérationnel, l'évolution des méthodes réglementaires de mesure, et les applications du machine learning à ce domaine, avant de positionner précisément la contribution de ce travail. La seconde partie présente la démarche méthodologique retenue, l'apurement et l'analyse exploratoire de la base P-COLD, puis les résultats obtenus par chacun des trois modèles, leur comparaison, et une discussion critique de leurs apports et de leurs limites, permettant en conclusion de statuer sur la validité des trois hypothèses formulées.

# ★★★★★★★★ CHAPITRE 1 ★★★★★★★★
# CADRE THÉORIQUE DE L'ÉTUDE

## 1.1. REVUE DE LITTÉRATURE

### 1.1.1. Le risque opérationnel (définitions et Importances)

Le Comité de Bâle définit le risque opérationnel comme le risque de perte résultant de processus internes, de personnes ou de systèmes défaillants, ou d'événements externes. Cette définition inclut le risque juridique, mais exclut volontairement les risques stratégiques et de réputation, ceux-ci se situant hors du périmètre prudentiel réglementaire (Comité de Bâle, Basel Framework, chapitre OPE). Cette définition trouve son origine dans l'accord Bâle II de 2004. Depuis 2019, elle a été absorbée dans un cadre unique et régulièrement actualisé, le Basel Framework, qui rassemble désormais l'ensemble des standards prudentiels du Comité.

Selon Danièle N. (2006)[Nouy, 2006], le risque opérationnel prend en compte des risques juridiques, administratifs, les risques d'ordre technique ou technologique, tels que les risques associés aux systèmes d'information, de gestion et de procédures, les risques environnementaux, tels que les risques économiques, politiques, sociaux systémiques, climatiques.Toutefois, le risque opérationnel exclus le risque stratégique et le risque de réputation. Ce qui est n'est pas facile, car cette agrégation de risques hétérogènes rend délicate toute identification précise du risque opérationnel, d'autant plus que ses manifestations sont souvent difficiles à isoler.

Dans les faits, l'application de ce cadre reste néanmoins assez inégale d'un établissement à l'autre. Les travaux de l'ORX montrent que si la majorité des banques utilisent des catégories de causes fondées sur les quatre facteurs bâlois, personnes, processus, systèmes, facteurs externes, un certain nombre d'entre elles ont développé leurs propres taxonomies, notamment pour des risques plus récents comme la cybersécurité ou le risque lié aux tiers (ORX, 2020)[ORX, 2020]. Cette hétérogénéité en dit long sur les limites d'un cadre pensé, à l'origine, pour des risques plus traditionnels.

Ces dernières années, le risque opérationnel est devenu l'un des thèmes les plus étudiés dans le domaine bancaire. Ce risque, longtemps considéré comme moins fréquent que les autres types de risques bancaires, n'a pas cessé de prendre de l'importance, aussi bien pour les autorités de régulation que pour les banquiers et les chercheurs académiques. Un tel intérêt est notamment motivé par la multiplication des scandales financiers liés aux risques opérationnels, ayant entraîné des pertes financières substantielles (De Fontnouvelle et al., 2006)[De Fontnouvelle et al., 2006]. La faillite de la banque d'affaires Barings, en 1995,

suite aux spéculations de l'un de ses traders Nick Leeson illustre bien ces propos. En effet, en tentant de rattraper ses pertes et de couvrir ses positions, ce dernier a dû emprunter des sommes importantes. Le retournement des marchés asiatiques, suite au tremblement de terre de Kobé, a eu raison de ses positions et a entraîné la chute de la banque britannique, qui a cumulé des pertes s'élevant au double de son capital. Plus récemment, l'affaire Kerviel a coûté à la Société Générale 4,9 milliards d'euros en 2008. La fraude du trader Kerviel, qui a réussi à contourner les procédures de contrôle interne, met en exergue l'importance de la gestion de ce type de risque. Ces deux affaires ont certes fait couler beaucoup d'encre mais elles ne représentent pas les uniques cas de fraude et de dysfonctionnement des contrôles bancaires.De nombreuses autres affaires de tromperie, ayant entraîné des pertes significatives, ont défrayé la chronique (Chernobai, 2007, p.4)[Chernobai et al., 2007]. Quant à la crise des subprimes, souvent attribuée à la complexité des produits financiers structurés, elle est en grande partie due à une négligence humaine, et donc à un risque opérationnel (Thirlwell, 2010 ; Thirlwell, 2011)[Thirlwell, 2010][Thirlwell, 2011]. En effet, les traders n'ont pas examiné avec précision la composition des produits structurés, ni évalué sérieusement les risques. Par ailleurs, la crise de liquidité ayant suivi la crise des subprimes est avant tout une crise de confiance engendrée par un comportement humain et relevant donc du risque opérationnel. De plus, le risque opérationnel n'étant pas limité aux fraudes et aux erreurs humaines, il s'est aussi matérialisé lors des catastrophes naturelles ou environnementales, telles que les attentats du 11 septembre 2001, le tremblement de terre au Japon en 2011 ou encore les craintes du bug informatique, suscitées par le passage à l'an 2000. Parallèlement, la digitalisation des services bancaires, le développement des paiements électroniques et l'augmentation des cyberattaques ont renforcé la nécessité de disposer de dispositifs de surveillance plus performants. Les banques ne doivent plus seulement mesurer les pertes passées, mais également être capables d'anticiper les risques futurs grâce à des outils d'analyse prédictive.

Dès lors, plusieurs interrogations portent sur l'intérêt attribué au risque opérationnel dans les différentes réglementations prudentielles. En effet, face aux inquiétudes concernant l'efficacité des pratiques de gestion du risque opérationnel, les autorités de régulation ont soulevé la question de la réglementation de ce risque, un risque qui a été introduit dans le cadre des accords de Bâle II (Basel Committee on Banking Supervision, 2005)[Basel Committee on Banking Supervision, 2005]. Il est donc important de connaitre la place du risque opérationnel dans la réglementation prudentielle, de savoir comment a-t-elle évolué au cours du temps, d'identifier les mesures qui ont été prises suite aux nombreuses faillites bancaires d'une part et d'autre part savoir comment faire évoluer la surveillance du risque opérationnel.

### 1.1.2. Les différentes catégories du risque opérationnel.

Le comité de bale sur le contrôle bancaire distingue sept grandes catégories de risque opérationnel. La première, la fraude interne, regroupe les actes commis par des collaborateurs qui cherchent à contourner la réglementation, la loi ou les politiques internes de l'entrepris, ou qui s'en écartent délibérément.À l'inverse, la fraude externe rassemble les actes frauduleux commis par un tiers extérieur à l'organisation, que ce soit par violation ou contournement de la loi. Vient ensuite la catégorisé liée aux pratiques en matière d'emploi et de sécurité sur le lieu de travail, qui couvre les manquements aux codes du travail, aux normes sanitaires ou de sécurité, ainsi que les indemnisations pouvant résulter de poursuites judiciaires pour accidents du travail ou discrimination.

Un autre volet important concerne les pratiques envers les clients, les produits et l'activités commerciales. Il s'agit ici des défaillances, intentionnelles ou non, dans le respect des engagements professionnels envers les clients mais aussi des risques liés à nature ou à la conception même d'un produit. Les dommages aux biens matériels constituent une cinquième catégorie, regroupant les pertes subies par les actifs réels à la suite de catastrophes naturelles ou d'autres événements similaires. Le risque opérationnel englobe également l'interruption d'activité et les pannes de systèmes qui peuvent fragiliser durablement le fonctionnement d'un établissement. En fin la dernière catégorie touche à l'exécution des opérations, à la livraison et à la gestion des processus, c'est-à-dire aux défaillances qui peuvent survenir dans le traitement des transactions ou dans les relations avec les contreparties et les fournisseurs.

En croisant ces sept catégories d'événements avec les huit lignes métier de la banque, on obtient une matrice de cinquante-six cellules réglementaires correspondant à autant de sources potentielles de risques d'exploitation. Ces huit lignes métier recouvrent le financement d'entreprise, les activités de marché, la banque de détail, la banque commerciale, le paiement et la compensation, les agences bancaires et le réseau, la gestion d'actifs, ainsi que le courtage de détail.

### 1.1.3. Évolution des méthodes de mesure de risques opérationnels de Bâle

Historiquement, le Comité de Bâle propose trois méthodes pour calculer le capital requis au titre du risque opérationnel. l'approche indicateur de base (BIA), l'approche standardisée (TSA), et l'approche par mesure avancée (AMA).

Les deux premières calculent le capital comme une simple fonction du produit net bancaire (PNB). À l'époque de Bâle II (2004), le risque opérationnel est une notion réglementaire encore neuve jusque-là, seuls les risques de crédit et de marché faisaient l'objet d'exigences de fonds propres formalisées. Le Comité de Bâle cherche donc une méthode facilement applicable à toutes les banques, quelle que soit leur sophistication, sans exiger une infra-

structure de données ou de modélisation qu'elles ne possèdent pas encore. Le PNB sert de proxy grossier : on suppose qu'une banque plus grande, générant plus de revenus, est mécaniquement exposée à davantage de risque opérationnel. Cependant, cette approche ne différencie ni le profil de risque réel de l'établissement, ni la qualité de sa gestion des risques, ni la nature de ses activités (une banque de détail et une banque de marché n'ont pas la même exposition opérationnelle pour un même PNB).

Face à cette limite, le Comité de Bâle introduit l'AMA, qui laisse chaque établissement construire son propre modèle interne, à condition de le justifier sur les 56 cellules règlement. L'objectif devient d'aligner le capital réglementaire sur le risque économique réel de chaque banque, plutôt que sur un indicateur d'activité forfaitaire. Cela répond à une double pression : les banques les plus sophistiquées veulent un capital reflétant leur gestion effective du risque et le régulateur veut inciter à l'investissement dans la collecte de données de pertes et la modélisation quantitative. C'est dans ce contexte qu'émerge la Loss Distribution Approach (LDA), formalisée par Frachot, Georges et Roncalli (2001).Pour chaque cellule de risque, la banque estime séparément la fréquence annuelle des événements de perte et leur sévérité, combine ces deux distributions pour obtenir la perte totale attendue, et fixe le capital au quantile à 99,9% de cette distribution le niveau de perte qui ne devrait être dépassé qu'une fois tous les mille ans en moyenne. Cependant, en laissant chaque banque construire son propre modèle, l'AMA produit des résultats peu comparables d'un établissement à l'autre. Deux banques au profil de risque similaire peuvent afficher des niveaux de capital très différents selon les choix de modélisation retenus (distribution de sévérité, méthode d'agrégation, traitement des données externes). Cette hétérogénéité mine la crédibilité du dispositif aux yeux des superviseurs, qui peinent à comparer et à valider ces modèles internes

En 2017, le Comité de Bâle remplace la BIA, la TSA et l'AMA par une méthode unique, la Standardised Measurement Approach (SMA), qui combine un indicateur d'activité et un multiplicateur fondé sur les pertes historiques de la banque. La SMA cherche à concilier deux exigences qui semblaient inconciliables avec l'AMA. La comparabilité entre banques (en imposant une formule unique) et la sensibilité au risque (en intégrant, via le multiplicateur, l'historique de pertes propre à chaque établissement contrairement à la BIA/TSA qui l'ignoraient totalement). C'est une évolution qui tire les leçons des deux échecs précédents.La BIA/TSA étaient trop insensibles au risque réel, l'AMA était trop peu comparable et trop complexe à superviser. Son adoption reste toutefois progressive et non uniforme. Appliquée dans l'Union européenne depuis janvier 2025 et au Royaume-Uni depuis janvier 2026, elle n'est pas encore fixée dans sa version définitive aux États-Unis, où une proposition de mars 2026 suggère que le pays n'appliquera pas le multiplicateur de pertes historiques signe que le débat sur le bon équilibre entre simplicité et sensibilité au risque n'est toujours pas clos. La limite actuelle, révélée par la littérature Briceño

(2025)[Briceño, 2025] adresse trois critiques à la SMA, qui montrent que la boucle n'est peut-être pas bouclée.

L'Instabilité du capitale constitue une première limite.Le capital calculé peut varier fortement d'une année sur l'autre sans changement du profil de risque de la banque. Une seconde limite tient en la super-additivité du modèle.Diviser une entité en plusieurs lignes métier augmente paradoxalement le capital total requis, alors que l'AMA savait capter les effets de diversification entre lignes.En fin ce dispositif se révèle incapacité à intégrer l'environnement d'affaires et les contrôles internes, deux dimensions pourtant essentielles à une gestion complète du risque opérationnel.

### 1.1.4. Data analytics et machine learning appliqués au risque

Le recours au machine learning dans la gestion des risques bancaires ne relève plus de l'expérimentation isolée mais d'une tendance de fond, documentée par une littérature devenue suffisamment abondante pour faire l'objet de synthèses systématiques. Heß et Damásio (2025)[Heß and Damásio, 2025], qui recensent 46 études publiées sur une décennie, montrent que le risque opérationnel figure parmi les domaines les mieux couverts par cette littérature, aux côtés du risque de crédit et du risque de marché. Ce constat rejoint celui, plus ancien, de Leo, Sharma et Maddulety (2019)[Leo et al., 2019], qui avaient déjà relevé que le risque opérationnel restait nettement moins étudié que le risque de crédit, alors même que les volumes de données internes disponibles au sein des banques s'y prêteraient particulièrement bien. Les applications identifiées vont de la cybersécurité à la détection de fraude, en passant par la gestion de la relation client et l'évaluation des risques liés aux tiers.

Les réseaux bayésiens occupent une place particulière dans cette littérature, précisément parce qu'ils permettent de dépasser la lecture purement statistique du risque opérationnel pour y intégrer une dimension organisationnelle. Sanford et Moosa (2015)[Sanford and Moosa, 2015] développent un modèle bayésien appliqué aux opérations de finance structurée, dont l'intérêt ne réside pas seulement dans sa capacité prédictive, mais dans le fait qu'il formalise explicitement les interdépendances entre facteurs humains, procéduraux et systémiques que les méthodes de mesure réglementaires, telles que décrites en 1.1.2, peinent à représenter. Les auteurs montrent que ce type de modèle peut être utilisé comme un outil d'apprentissage organisationnel : en rendant visibles les chaînes de causalité entre défaillances de contrôle et pertes effectives, le réseau bayésien devient un support de diagnostic autant qu'un instrument de prévision.

La détection de fraude demeure toutefois le terrain sur lequel se concentre le plus grand nombre de travaux, au point de constituer presque un sous-champ à part entière. George, Alam et Hasan (2025)[George et al., 2025], en analysant 118 études consacrées à ce su-

jet, dressent un constat qui mérite d'être nuancé plutôt que résumé. Les méthodes supervisées, arbres de décision et régression logistique en tête, restent largement privilégiées par les praticiens, non pas parce qu'elles offrent les meilleures performances prédictives, mais parce qu'elles demeurent interprétables. Cette préférence révèle une tension structurante que confirme la revue systématique de Černevičienė et Kabašinskas (2024)[Černevičienė and Kabašinskas, 2024] .En analysant 138 études consacrées à l'IA explicable en finance, les auteurs montrent que la détection de fraude et l'évaluation du risque figurent parmi les domaines où cette tension entre performance et explicabilité est la plus vive, les techniques les plus employées pour la résoudre étant les méthodes d'attribution de caractéristiques telles que SHAP. Cette exigence d'explicabilité n'est pas qu'une préférence méthodologique, elle répond directement à une demande réglementaire, les superviseurs exigeant une justification documentée de toute décision automatisée affectant un client.

Les méthodes non supervisées de détection d'anomalies se développent en parallèle, et pour une raison inverse. Elles ne cherchent pas à reproduire une classification connue mais à repérer des écarts par rapport à un comportement normal, ce qui les rend particulièrement adaptées aux formes de fraude émergentes, pour lesquelles aucun exemple étiqueté n'existe encore. Quant aux réseaux de neurones profonds, en particulier les architectures récurrentes et convolutionnelles, ils affichent des performances élevées sur les données de transactions, mais souffrent de deux limites qui reviennent de façon récurrente dans la littérature.Une interprétabilité fortement réduite, qui les rend difficilement compatibles avec les exigences de gouvernance du risque opérationnel, et une complexité de déploiement en environnement réel qui freine encore leur adoption à grande échelle.

Un même problème méthodologique traverse ces deux corpus de recherche, celui du déséquilibre des données. Les événements de fraude, tout comme les événements de perte opérationnelle au sens large, restent rares au regard du volume total de transactions traitées, ce qui complique sérieusement l'apprentissage des modèles. Ce point ne relève pas d'un simple détail technique mais engage une réflexion méthodologique de fond, qui devra être prise en compte directement dans la méthodologie de ce mémoire (section 2.1), notamment dans le choix des modèles et des métriques d'évaluation retenues.

Ce que révèle, infine, cette littérature, c'est moins une supériorité générale du machine learning sur les approches statistiques traditionnelles qu'une complémentarité encore mal exploitée, et freinée par un déficit persistant de recherche appliquée spécifiquement au risque opérationnel, ainsi que le relevaient déjà Leo, Sharma et Maddulety (2019)[Sanford and Moosa, 2015]. Les modèles bayésiens et supervisés parviennent à capter des relations complexes entre facteurs de risque, y compris organisationnels, mais ils restent, pour l'essentiel, cantonnés à des tâches ponctuelles sans jamais s'intégrer véritablement à un dispositif de pilotage global du risque opérationnel à l'échelle de l'établissement.

C'est précisément cet écart entre la richesse des capacités techniques et la pauvreté de leur intégration organisationnelle qui structure le positionnement de ce mémoire.

### 1.1.5. Positionnement de la recherche

Trois constats se dégagent des points précédents.

D'abord, le cadre de Bâle impose une définition et une typologie communes du risque opérationnel (1.1.1), mais son application demeure inégale dans la pratique, en particulier face à des risques émergents comme la cybersécurité. Les travaux académiques élargissent cette lecture réglementaire en s'intéressant aux déterminants humains et organisationnels des pertes opérationnelles, un angle que le seul cadre normatif peine à couvrir.

Cette même limite ressort de l'analyse des méthodes de mesure (1.1.2). Si la Loss Distribution Approach offre une réelle rigueur statistique, elle reste coûteuse à mettre en œuvre. Quant à la Standardised Measurement Approach qui l'a progressivement remplacée depuis 2017, elle simplifie certes le calcul du capital, mais au prix d'une perte de sensibilité au risque réel de chaque établissement Briceño (2025)[Briceño, 2025] la montre instable, superadditive, et incapable d'intégrer des facteurs qualitatifs comme les contrôles internes. Autrement dit, la SMA échoue précisément là où la lecture organisationnelle de Pakhchanyan (2016)[Pakhchanyan, 2016] insistait.

Le machine learning vient combler, en partie seulement, ce vide (1.1.3). Les modèles bayésiens comme les modèles supervisés parviennent à capter des relations complexes entre facteurs de risque, y compris organisationnels. Cependant ils restent, pour l'essentiel, cantonnés à des tâches ponctuelles, détecter une fraude, classer une anomalie, sans jamais s'intégrer véritablement à un dispositif de pilotage global du risque opérationnel.

C'est précisément cet espace laissé vacant que ce mémoire propose d'occuper, à travers un outil qui articule une base statistique inspirée de la LDA, des modèles prédictifs de machine learning, et un module de reporting destiné au pilotage du risque à l'échelle de l'établissement. Une approche qui conserve la rigueur que la SMA a sacrifiée, qui relie les capacités prédictives du machine learning à un usage opérationnel concret, et qui laisse enfin une place aux facteurs organisationnels que la seule approche quantitative ne peut saisir à elle seule. Le problème de recherche de ce mémoire peut ainsi se formuler de la façon suivante : comment concevoir un outil de détection et de pilotage du risque opérationnel qui combine la rigueur de la modélisation statistique traditionnelle avec les capacités prédictives du machine learning, afin de dépasser les limites de l'approche réglementaire standardisée actuelle ?

# ★★★★★★★★ CHAPITRE 2 ★★★★★★★★
# CADRE MÉTHODOLOGIQUE DE L'ÉTUDE

La base P-COLD, sur laquelle s'appuie ce mémoire, présente plusieurs limites. D'abord elle documente le système bancaire chinois, dont le cadre réglementaire ne peut être tenu pour équivalent à celui visé par l'outil propos. La chine n'a pas encore fait l'objet d'une évaluation de conformité (RCAP) du comité de Bale portant sur les révisions de 2017 du dispositif, dont la SMA, cette évaluation n'étant prévue qu'au dernier trimestre 2029, quand l'union européenne applique déjà ce cadre depuis janvier 2025 et le Royaume-Uni depuis Janvier 2026. Les pertes recensées dans P-COLD ne reflète donc pas un environnement de contrôle et de reporting reconnu conforme aux standards internationaux.Ensuite, la base est construite à d'événements rendus publics par la presse, et non de déclarations internes exigées par une réglementation contraignante comme celle du comité de Bale pour une approche LDA. Les pertes de faible montant, non médiatisées, y sont largement sous-représentées, ce qui biaise l'estimation des distributions de fréquence et de sévérité.Enfin, la base souffre de lacune de complétude. Sur 3725 événements recensés entre 1986 et 2022, 56% n'ont pas de date de clôture renseignée, et la couverture s'effondre après 2019.L'identité des banques est également anonymisées, empêchant de relier les pertes à des variables comme la taille de l'établissement, pourtant utilisées par les approches BIA et SMA.

**Source** : Basel Committee on Banking Supervision, 2026, « RCAP Assessment Schedule for Member Jurisdictions », Bank for International Settlements, consulté le 24 août 2026, disponible sur `https://www.bis.org/bcbs/implementation/rcap_aoi.htm` jurisdictions

## 2.1. POPULATION D'ÉTUDE ET SOURCES DES DONNÉES

### 2.1.1. Population d'étude

Cette étude porte sur l'ensemble des risques opérationnels survenus au sein des établissements bancaires chinoises opérant sur le territoire et répartis sur une trentaine de provinces ou régions. De façon précises, il s'agit des 3725 événements de pertes de types opérationnelles recensés entre 1896 et 2022 au sein de ladite établissement bancaire. Ici une unité statistique est un événement survenu dans la période définie et non une banque.

### 2.1.2. Source des données

Les données utilisées dans le cadre de cette étude ont été extraites de la base P-COLD téléchargé sur le site https://doi.org/10.6084/m9.figshare.23940069.v3. Pour chaque événe-

ment, la base apporte des informations indispensables pour la réalisation de l'ensemble des analyses en vu d'atteindre les objectifs de la recherche. Elle comprend les variables suivantes : Event ID, Occurrence year, Occurrence month, End year, End month, Loss amount, Bank involved code, Province occurred, City occurred, Causal factor, Event type, Business line. L'ensemble de ces informations constituent le socle des analyses quantitatives menées dans cette étude.

### 2.1.3. Apurement et prétraitement des données

Le traitement des données a été réalisé de manière à la fois simple et rigoureuse. Un traitement spécifique est effectué sur chaque variable de la base.

Pour les variables cibles (Causal Factor, Event type, Business line), seulement deux lignes sur l'ensemble des 3725 sont simultanément vides. Ces trois lignes seront tout simplement supprimer de la base car il n'existe pas de raisonnement pouvant nous permettre de deviner une catégorie baloise à partir des autres champs.

Pour les dates (Occurrence year, Occurrence month, End year, End month), il manque respectivement 67, 630, 1600 et 2088 événements. C'est un point délicat et pour remédier à ce dernier, deux logiques différentes s'imposent. Premièrement, les 67 lignes sans années de début doivent être exclus pour les analyses temporelles car aucune reconstruction fiable n'est possible. Deuxièmement, l'absence de date de fin n'est pas aléatoire. Elle traduit dans la majeure partie des cas des événements dont l'issue judiciaire ou financière n'était pas connue lors des collectes ou non mentionnée dans l'article source. Nous n'allons ni les supprimer ni les imputer par des valeurs arbitraires, cependant nous créerons une variable de durée avec une modalité explicite « durée indéterminée », et traiter cette absence comme une information que comme un trou à combler.

Quant à la variable « Bank involved code », elle comporte deux problèmes à savoir : 1014 valeurs manquantes et certaines lignes admets plus d'un code. Ainsi un même évènement implique plusieurs banques. Pour ce fait, nous allons conserver uniquement le premiers code comme établissement « principal » pour les analyses par banque d'une part et d'autre part, nous allons les conserver pour des statistiques agrégées.

S'agissant ensuite de la variable localisation (Province occurred, City occurred,), il y a 723 provinces et 872 villes manquantes. Ces champs ne sont utiles qu'a l'analyse descriptive de la répartition géographique. Ainsi, nous allons les exclus ligne par ligne des seuls tableaux et graphiques géographiques concernés.

A l'égard de la variable montant de perte (Loss amount), trois valeurs manquantes seulement seront exclure. La distribution est extrêmement asymétrique (de $5 \times 10^{-6}$ à 41 millions de dizaines de milliers de CNY) ce qui est cohérent avec la nature de la variable. Nous allons appliquées une transformation logarithmique pour les analyses descriptives et

la modélisation pour faciliter l'ajustement des modèles de sévérité et la stabilisation de la variance.

Enfin, vérifier que les intitulés de province/City et les modalités des variables catégorielles sont bien orthographiés de façon homogène.

### 2.1.4. Présentation des variables de l'étude

Le tableau ci-dessous présente les douze variables de la base de données P-COLD à travers leurs types et aussi une petite description.

TABLE 2.1 – Description des variables de la base de données

| N | Variable | Type | Description |
|---|---|---|---|
| 1 | Event ID | Identifiant | Identifiant unique de l'événement |
| 2 | Occurrence year | Numérique | Année de début |
| 3 | Occurrence month | Numérique | Mois de début |
| 4 | End year | Numérique | Année de fin |
| 5 | End month | Numérique | Mois de fin |
| 6 | Province occurred | Catégorielle | Localisation de l'événement |
| 7 | City occurred | Catégorielle | Ville de déroulement de l'événement |
| 8 | Bank involved code | Catégorielle anonymisée | Code permettant d'identifier la banque concernée |
| 9 | Causal Factor | Catégorielle | Facteur source de l'événement |
| 10 | Event type | Catégorielle | Typologie baloise des événements de risque opérationnel |
| 11 | Business line | Catégorielle | Ligne métier baloise concernée |
| 12 | Loss amount | Numérique continu | Montant de la perte en CNY |

*Source : Auteur, donnée de l'étude*

## 2.2. CONSTRUCTION DES PERTES LOGARITHMIQUE

De son nom « Loss amount », cette variable représentant le montant des pertes et par nature, elle est une variable financière susceptible de présenter une distribution fortement asymétrique et à queue épaisse propriété largement documentée pour les pertes opérationnelles dans la littérature (De Fontnouvelle et al, 2006 ; Frachot, Georges et Roncalli 2001)[De Fontnouvelle et al., 2006][Frachot et al., 2001]. Pour stabiliser la variance et limiter l'influence disproportionnée des événements extrêmes sans imposer une normalité stricte à « Loss amount », une transformation logarithmique sera appliquée à cette dernière avant toute modélisation.

$$\text{LogLoss} = \ln(\text{Loss amount})$$

## 2.3. ANALYSE EXPLORATOIRE ET TESTS STATISTIQUES PRÉALABLES

### 2.3.1. Analyse descriptive

Avant tout modélisation, une analyse exploratoire approfondie sera conduite sur l'ensemble des variables présenté dans le tableau 1. Elle portera particulière sur : la distribution du montant des pertes (moyennes, médianes, écart-types, asymétrie(skewness), aplatissement), la répartition des événements suivants les catégories baloises dans le temps.

### 2.3.2. Analyse de stationnarité et tests statistiques

La base de données P-COLD couvre plus de trente ans, la stabilité temporelle des séries de fréquence et de sévérité des pertes sera testée afin de vérifier qu'aucune rupture structurelle ou tendance non maitrisée ne biaise l'analyse. Un test de Dickey-Fuller augmenté (ADF) sera appliqué à la série annuelle du nombre d'événement ainsi qu'à la série de la sévérité moyenne (exprimée en log) pour déterminer si ces séries sont stationnaires en niveau ou si une différenciation est nécessaire. En ce qui concerne les dernières années de la période de couverture, une attention particulière sera portée pour déterminer l'existence ou non d'effet de troncature lié au mode de construction de la base (Collecte par voie de presse, avec un délai probable entre survenue d'un évènement et sa médiatisation ou sa judiciarisation)

### 2.3.3. Modèle de régression logistique multinomiale et son estimation

La nature de la variable à expliquer conditionne le choix de la méthode économétrique. Ici, le but est de modéliser la probabilité de survenue d'un événement de perte opérationnelle. En d'autres termes, on aura une variable dichotomique $Y_i$ prenant la valeur 1 lorsque l'évènement se réalise et 0 dans le cas contraire. Parmi les modèles disponibles, probit et logit, le choix s'est porté sur le second pour deux raisons. D'une part, les coefficients du modèle logit se prêtent à une interprétation en terme d'odds ratios $OR = \exp(\beta_k)$, plus directement mobilisable dans un contexte bancaire ou l'analyse en termes de rapport de chances est déjà une pratique courante des équipes de risques ? D'autre part, la fonction logistique offre une expression analytique simple de la vraisemblance, ce qui facilite la convergence de l'algorithme d'estimation sur un jeu de données présentant, comme cela sera discuté plus loin, un déséquilibre marqué entre classes.

De façon formellement, la probabilité qu'un événement de perte opérationnelle survienne, conditionnellement à un ensemble de caractéristique $X_i$(nature de l'événement, ligne métier,

montant, zone géographique), s'écrit :

$$P(y_i = 1 \mid X_i) = F(X_i\beta) = \frac{1}{1 + \exp(-X_i\beta)} \tag{2.1}$$

Ce modèle peut être fondé sur une variable latente $y_i^*$, reflétant un processus inobservable sous-jacent à la matérialisation du risque, telle que :

$$y_i^* = X_i\beta + u_i, \qquad y_i = \begin{cases} 1 & \text{si } y_i^* > 0 \\ 0 & \text{si } y_i^* \leq 0 \end{cases} \tag{2.2}$$

Sous l'hypothèse que$u_i$ suit une distribution logistique.L'estimation des paramètres $\beta$ repose sur la méthode du maximum de vraisemblance. Pour un échantillon de $n$ observations, la fonction de vraisemblance s'écrit comme le produit, sur l'ensemble des individus, de la probabilité d'observer chaque valeur réellement prise par $y_i$. Sa log-transformation, plus commode à maximiser, s'écrit :

$$\log L(\beta) = \sum_i \left[ y_i \log F(X_i\beta) + (1 - y_i) \log(1 - F(X_i\beta)) \right] \tag{2.3}$$

La condition du premier ordre, obtenue en dérivant cette expression par rapport à $\beta$, se simplifie considérablement dans le cas logit, la densité logistique vérifiant la propriété

$$f(X_i\beta) = F(X_i\beta)\left[1 - F(X_i\beta)\right] \tag{2.4}$$

Le vecteur gradient prend alors une forme particulièrement compacte :

$$\sum_i (y_i - F(X_i\beta))X_i = 0 \tag{2.5}$$

En l'absence de solution analytique fermée, du fait de la non-linéarité de la log-vraisemblance, la résolution est obtenue par un algorithme d'optimisation itératif, l'algorithme de Newton-Raphson étant le plus couramment implémenté dans les logiciels statistiques usuels. La convergence est atteinte lorsque la variation du vecteur de paramètres estimé entre deux itérations successives devient inférieure à un seuil de tolérance fixé.

Sous les hypothèses standard du modèle, l'estimateur du maximum de vraisemblance ainsi obtenu est convergent et asymptotiquement normal, ce qui permet de construire les tests de significativité usuels, notamment le test de Wald sur les coefficients individuels et le test du rapport de vraisemblance sur des contraintes portant sur plusieurs paramètres, à partir de la matrice d'information de Fisher.

### 2.3.4. Modèle Random Forest

Le Random Forest constituera le modèle intermédiaire de cette étude comparative. Il présente l'avantage de gérer nativement l'hétérogénéité des variables explicatives sans exiger de mise à l'échelle préalable, et se montre par ailleurs robuste face au déséquilibre des classes, grâce à la pondération des classes au sein de chaque arbre. Sans être aussi transparent qu'un modèle logit, il conserve tout de même un niveau d'interprétabilité correct à travers la mesure de l'importance des variables.

Concrètement, le modèle agrège un grand nombre d'arbres de décision, notés B. Chaque arbre est construit sur un échantillon bootstrap, c'est-à-dire un tirage aléatoire avec remise à partir de l'échantillon d'origine, et à chaque nœud de division, seul un sous-ensemble aléatoire de m variables, parmi les k variables explicatives disponibles, est proposé pour déterminer la meilleure séparation. Cette double randomisation, sur les observations comme sur les variables, a pour effet de décorréler les arbres entre eux, ce qui limite le surapprentissage dont souffre généralement un arbre de décision pris isolément.

Une fois entraîné, chaque arbre attribue à une observation donnée une classe, 0 ou 1, selon la majorité des observations d'apprentissage tombées dans la feuille terminale correspondante. La forêt combine ensuite ces B prédictions individuelles par un simple vote majoritaire :

$$\hat{Y}_i = \text{mode}\{T_1(X_i), \ldots, T_B(X_i)\} \tag{2.6}$$

L'observation $i$ est donc classée dans la catégorie qui recueille le plus de voix parmi l'ensemble des arbres. Le choix de chaque division, à l'intérieur d'un arbre, repose sur la minimisation de l'impureté de Gini des nœuds fils :

$$G = 1 - \sum_k p_k^2 \tag{2.7}$$

Où $p_k$ représente la proportion d'observations de la classe k dans le nœud considéré. En cumulant, sur l'ensemble de la forêt, la réduction d'impureté que chaque variable apporte aux divisions où elle intervient, on obtient une mesure de son importance, qui permet finalement de repérer les facteurs de risque les plus déterminants dans le modèle.

### 2.3.5. Modèle Gradient Boosting

Le Gradient Boosting sera mobilisé selon une double logique, reproduisant l'architecture fréquence/sévérité de la Loss Distribution Approach décrite en 1.1.2.En classification, pour prédire le type d'événement ; en régression, sur la variable logloss construite en 2.2, pour modéliser la sévérité des pertes conditionnellement aux variables explicatives disponibles. Contrairement au Random Forest, où les arbres sont construits indépendamment les uns des

autres puis agrégés, le Gradient Boosting construit ses arbres de façon séquentielle.Chaque nouvel arbre est entraîné pour corriger les erreurs commises par l'ensemble des arbres précédents. Le modèle prend la forme d'une somme pondérée de $M$ arbres :

$$F_M(X_i) = \sum_{m=1}^{M} \nu \cdot h_m(X_i) \tag{2.8}$$

Où $h_m$ désigne l'arbre ajouté à l'étape $m$, et $\nu$ un taux d'apprentissage compris entre 0 et 1, qui pondère la contribution de chaque arbre afin d'éviter qu'un seul arbre ne domine excessivement la prédiction finale. À chaque étape $m$, l'arbre $h_m$ n'est pas entraîné directement sur la variable à expliquer, mais sur les résidus, ou plus précisément sur l'opposé du gradient de la fonction de perte $L$ évaluée à l'étape précédente :

$$r_{im} = -\left[\frac{\partial L(y_i, F(X_i))}{\partial F(X_i)}\right]_{F=F_{m-1}} \tag{2.9}$$

Le nouvel arbre $h_m$ est ainsi ajusté de manière à approcher au mieux ces résidus $r_i m$, ce qui revient à faire progresser le modèle dans la direction qui réduit le plus la fonction de perte, un peu à la manière d'une descente de gradient, mais menée dans l'espace des fonctions plutôt que dans l'espace des paramètres.

### Volet classification (prédiction du type d'événement)

Pour la tâche de classification, la fonction de perte retenue est la log-vraisemblance négative, la même que celle utilisée pour le modèle logit :

$$L(y_i, F(X_i)) = -\left[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)\right], \quad \text{avec } \hat{p}_i = \frac{1}{1 + e^{-F(X_i)}} \tag{2.10}$$

Le Gradient Boosting cherche ainsi, arbre après arbre, à ajuster $F(X_i)$ de façon à rapprocher $\hat{p}_i$ des observations réelles, tout en conservant, par construction, la capacité des arbres de décision à capter des relations non linéaires entre les variables explicatives.

### Volet régression (modélisation de la sévérité)

Pour la sévérité des pertes, la variable à expliquer est logloss, transformation logarithmique du montant de la perte destinée à réduire l'asymétrie de sa distribution, déjà évoquée pour les méthodes de mesure du risque opérationnel en 1.1.2. La fonction de perte retenue est alors l'erreur quadratique :

$$L(y_i, F(X_i)) = (y_i - F(X_i))^2 \tag{2.11}$$

dont le gradient se réduit simplement au résidu ce qui $r_{im} = y_i - F_{m-1}(X_i)$, à chaque étape, à faire apprendre au nouvel arbre la partie de la sévérité que les arbres précédents n'ont pas encore su expliquer.

Cette double application, en classification puis en régression, permet de reconstituer, sur la base P-COLD, la logique de décomposition fréquence/sévérité propre à la LDA, tout en substituant à l'estimation paramétrique traditionnelle des distributions de fréquence et de sévérité une modélisation prédictive fondée sur les variables explicatives disponibles dans la base.

### 2.3.6. La méthode SHAP

La méthode SHAP sera appliquée en aval des modèles les moins directement interprétables, en particulier le Gradient Boosting, afin de décomposer chaque prédiction individuelle en contributions marginales de chaque variable répondant ainsi à l'exigence réglementaire de justification documentée des décisions automatisées, soulignée par Černevičienė et Kabašinskas (2024).Le principe de SHAP repose sur la valeur de Shapley, issue de la théorie des jeux coopératifs, où chaque variable explicative est traitée comme un joueur et la prédiction du modèle comme le gain à répartir entre eux. Pour une observation$X_i$, la prédiction se décompose comme suit :

$$F(X_i) = \varphi_0 + \sum_j \varphi_j \tag{2.12}$$

Où $\varphi_0$ est la prédiction moyenne du modèle sur l'échantillon, et $\varphi_j$ la contribution de la variable $j$ à l'écart entre la prédiction individuelle et cette moyenne. Cette contribution s'obtient en moyennant l'effet marginal de la variable $j$ sur l'ensemble des combinaisons possibles de variables auxquelles elle peut être ajoutée, ce qui garantit que la somme des $\varphi_j$ reconstitue exactement la prédiction individuelle.

Dans le cas du Gradient Boosting, ce calcul est rendu praticable par l'algorithme TreeSHAP, qui exploite la structure des arbres pour obtenir les valeurs de Shapley de manière exacte et rapide. SHAP permet ainsi d'identifier, pour chaque événement de perte prédit, les variables qui ont le plus pesé dans la décision du modèle, apportant une réponse concrète à la tension entre performance et explicabilité

# ★★★★★★★★ CHAPITRE 3 ★★★★★★★★
# PRÉSENTATION DES RÉSULTATS

## 3.1. APUREMENT ET PRÉTRAITEMENT DES DONNÉES

Après apurement de la base P-COLD, nous avons un échantillon de 3722 événements contre 3725 dans la base brute. En d'autres termes, seulement trois lignes ont été supprimées. Deux pour absence des trois variables cibles baloises, une pour montant de perte manquante. Le reste des valeurs manquantes (dates, localisation ; code banque) a été conservé sous forme de variables dérivées plutôt que supprimé.

TABLE 3.1 – Répartition et caractérisation des évènements de la base P-COLD

| Indicateur | Valeur | Taux |
|---|---|---|
| Nombre d'évènement brut | 3725 | 100 % |
| Nombre d'évènement après apurement | 3722 | |
| Nombre d'évènement supprimé | 3 | |
| Événement multi-banques | 433 | 11,6 % |
| Événement multi-provinces | 658 | 17,7 % |
| Durée connue | 1399 | 37,6 % |
| Durée indéterminée | 1647 | 44,2 % |
| Point de départ inconnu | 676 | 18,2 % |

*Source : Auteur, donnée de l'étude*

Pour la variable cible de classification, le regroupement en trois catégories rares sous Autres nous donnes : Internal fraud (35,8 %) ; Externat fraud (29,4 %), Execution, delivery & process management (16,1 %) ; Clients, products & business practices (14,6 %) ; Autres (2,3%).

## 3.2. ANALYSE EXPLORATOIRE ET TESTS STATISTIQUES PRÉALABLES

### 3.2.1. Analyse descriptive

Afin d'appréhender la dynamique des pertes sur la période d'étude, nous présentons ci-dessous une analyse entre l'évolution du montant de perte brute et celui du montant de perte logarithmiques. Cette double visualisation nous permet de visualiser les propriétés de stationnarité.

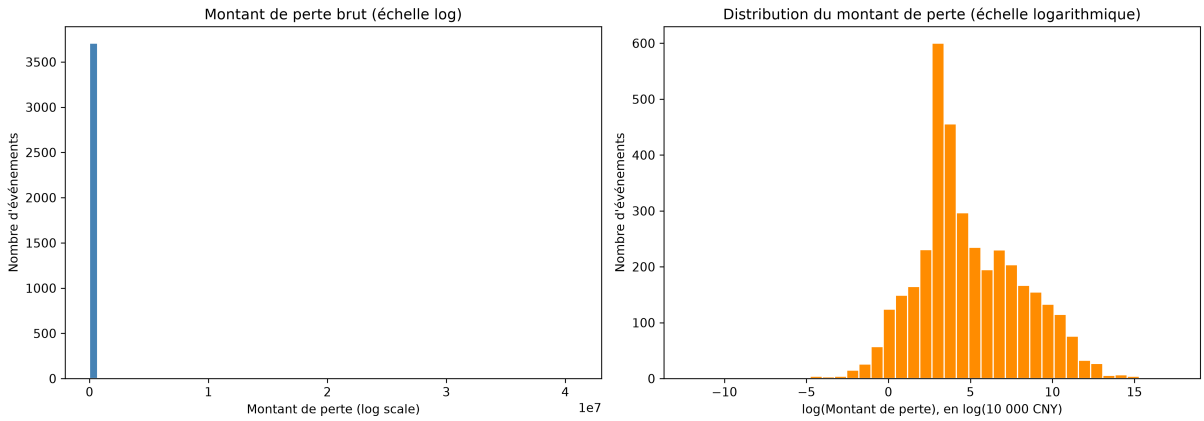



FIGURE 3.1 – Distribution des pertes : brute vs logarithmique

La distribution du montant de perte brute est extrêmement asymétrique, nous soupçonnons que quelques pertes exceptionnelles écrasent l'échelle. Cependant la transformation logarithmique ramène cette distribution à une forme visuellement symétrique ce qui confirme la pertinence du log pour la modélisation de la sévérité. Pour confirmer nos soupçons, nous procédons à une analyse quantitative. Le tableau ci-dessous résume les principaux indicateurs de tendances centrale et de dispersion des deux variables.

TABLE 3.2 – Indicateurs de tendance

| Indicateur | Loss amount (brut) | Loss amount log |
|---|---|---|
| Minimum | 0,00 | -12,21 |
| Moyenne | 28490,58 | 4,93 |
| Médiane | 70 | 4,25 |
| Écart-type | 704236,20 | 3,17 |
| Maximum | 41000000 | 17,53 |
| Skewness | 53,81 | 0,33 |
| Kurtosis | 3087,41 | 0,13 |

*Source : Auteur, donnée de l'étude*

Cette analyse quantitative confirme les soupçons soulevés par l'observation graphique. D'une part, il y a un grand écart entre la moyenne (28490,58) et la médiane (70) du montant de perte brut. De plus, un écart-type de 704236 traduit une dispersion extrême autour de quelques événements exceptionnels. Le skewness (53,8) et le kurtosis (3087), très éloignés des valeurs attendues d'une distribution normale (0). D'autre part, la transformation logarithmique corrige ce problème via l'obtention d'une moyenne de 4,93 contre une

médiane de 4,23, d'un écart-type qui chute à 3,17, et le skewness (0,33) comme le kurtosis (0,13) se rapprochent des valeurs d'une distribution normale.

Par railleur, une répartition annuelle des événements selon les cinq catégories baloises retenus, nous montre une nette prédominance des fraudes internes et externes sur l'ensembles de la période. Ces deux catégories représentent à elles seules près de deux tiers de l'échantillons. Le nombre total d'événements connait aussi une accélération marquée à partir de 2017, avant de chuter brutalement sur les dernières années de la période. La figure 2 ci-dessous illustre parfaitement cette description.

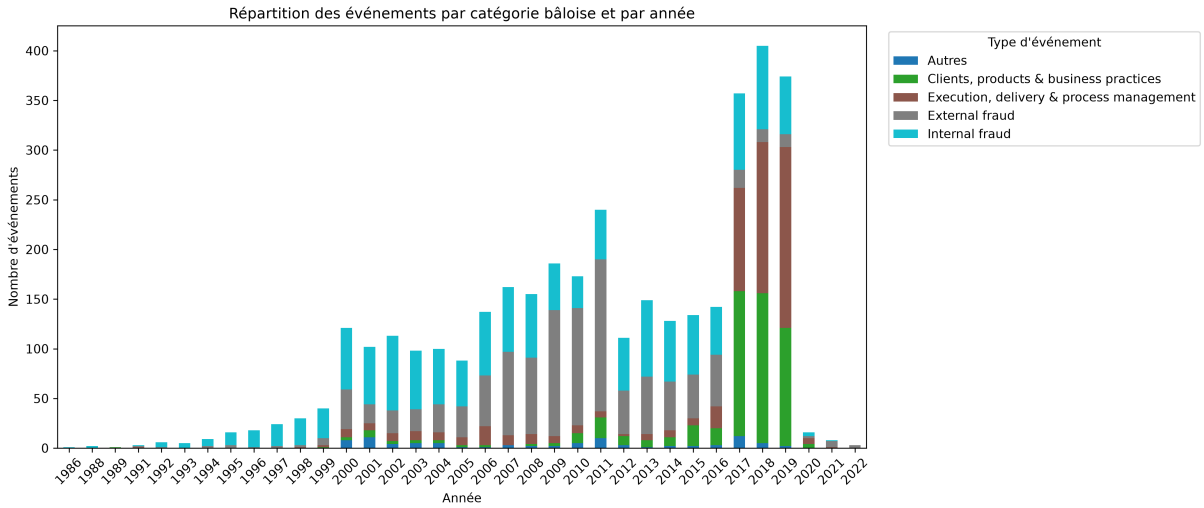



FIGURE 3.2 – Répartition empilée des événements par catégories baloise et par année

L'examen des dernières années révèle par ailleurs un effet de troncature manifeste. La fréquence passe de 405 événements en 2018 à un seuil de 3 en 2022.Cette chute brutale ne traduit vraisemblablement pas une baisse réelle du risque opérationnel. Néanmoins, elle traduit un artefact lié au mode de collecte de la base par voie de presse car les événements récents n'ayant pas encore eu le temps d'être médiatisés ou judiciarisés. Les années 2020-2022 seront donc traitées avec prudence dans les analyses temporelles, et cette limite sera discutée en les limites de ce document.

### 3.2.2. Analyse de la stationnarité et tests statistiques

La séries de fréquence annuelle et de sévérité annuelle moyenne(logloss) sont représentées sur la période 1986-2022 (figure 3).

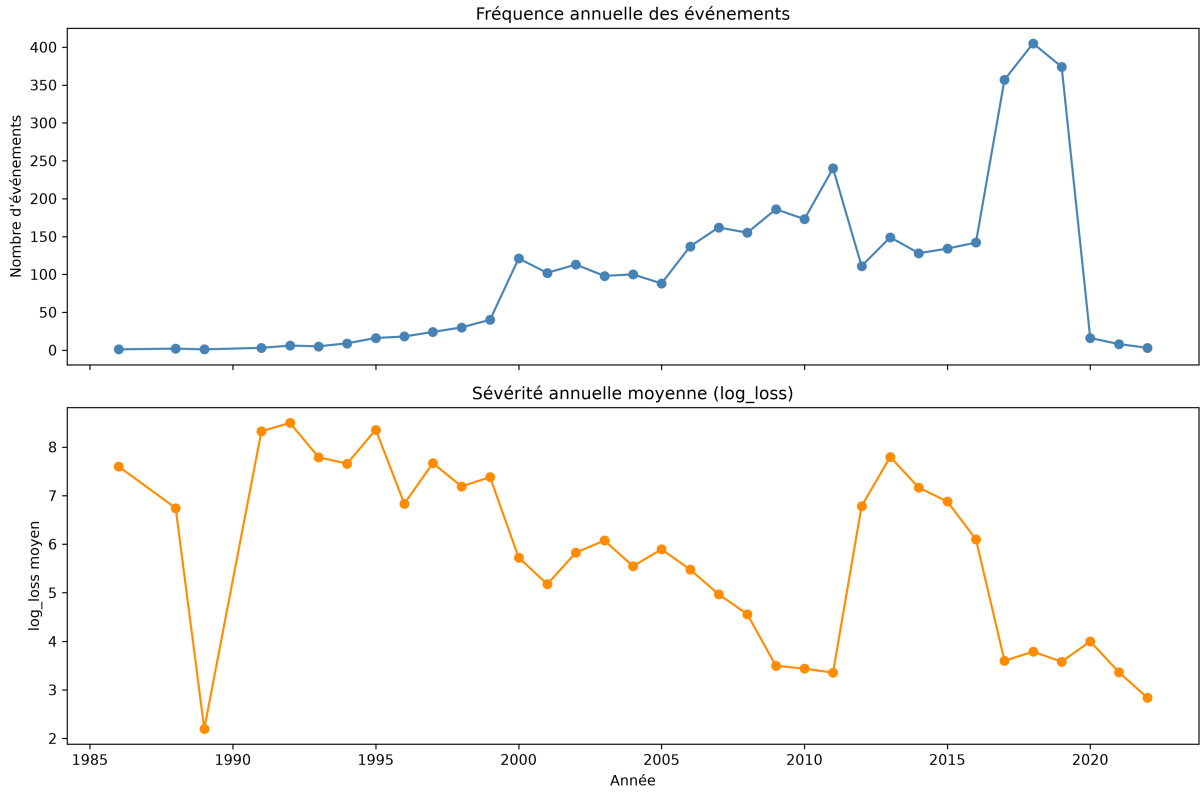



FIGURE 3.3 – Évolution annuelle de la fréquence et de la sévérité moyenne (logloss)

Le test de Dickey-Fuller augmenté est appliqué à chacune des deux séries afin de vérifier leur stationnarité. Les résultats, synthétisés dans le tableau 4, montrent que ni la fréquence annuelle qui a une p-value de 0,90 ni la sévérité annuelle moyenne ayant une p-value de 0,21 ne sont stationnaire au seuil de 5%. Une modélisation temporelle directe de ces séries nécessiterait donc une différenciation préalable.

TABLE 3.3 – Résultats des tests ADF

| Série | Statistique ADF | p-value | Nb lags | Val. Critique (5%) | Stationnaire (5%) |
|---|---|---|---|---|---|
| Fréquence annuelle | -0,4383 | 0,9035 | 7 | -2,9764 | Non |
| Sévérité annuelle | -2,1798 | 0,2137 | 1 | -2,9541 | Non |

*Source : Auteur, donnée de l'étude*

### 3.2.3. Modèle de régression logistique multinomiale et son estimation

Avant l'estimation du modèle, une inspection des variables explicative à montrer un problème de fuite de données concernant la variable Causal factor. Le tableau croisé entre cette variable et le type d'événement montre une association mécanique. En effet, un

facteur causal External event correspond à une fraude externe dans 92% des cas, et un facteur causal People correspond à une fraude interne dans 97% des cas. Il ne s'agit pas ici d'une relation économique à modéliser. Cependant, c'est une évidence de classification car le facteur causal détermine presque directement le type d'événement. Garder Causal Factor reviendrait à faire deviner au modèle une réponse qu'il connait déjà. Cette variable est donc écartée du modèle.

Le modèle logit est estimé sur les 3722 observations de l'échantillon apuré, avec pour variables explicatives la ligne métier Business line et le montant de perte transformé logloss. Par ailleurs, la convergence du modèle est obtenue après 7 itérations.

TABLE 3.4 – Résultat du modèle logit

| Variable | Coefficient ($\beta$) | Écart-type | z | p-value |
|---|---|---|---|---|
| const | -1,9065 | 0,4963 | -3,842 | 0,0001 |
| Asset management | -0,5516 | 0,4977 | -1,108 | 0,2677 |
| Commercial banking | 1,1135 | 0,5104 | 2,182 | 0,0291 |
| Corporate finance | -0,0119 | 0,8967 | -0,013 | 0,9894 |
| No business line | 0,8183 | 0,5151 | 1,589 | 0,1121 |
| Payment and settlement | -0,1629 | 0,5067 | -0,321 | 0,7479 |
| Retail banking | 2,7805 | 0,4988 | 5,575 | 0 |
| Retail brokerage | 0,8429 | 1,404 | 0,6 | 0,5483 |
| Trading & sales | -0,9064 | 0,5323 | -1,703 | 0,0886 |
| log_loss | 0,3703 | 0,02 | 18,514 | 0 |

*Source : Auteur, donnée de l'étude*

### Interprétation en odds ratios

Le tableau ci-dessous traduit ces coefficients en odds ratios, une mesure plus facile à interpréter. Un odds ratio supérieurs à 1 signifie que la variable augmente les chances que l'événement soit une fraude, un odds ratio inférieur à 1 signifie qu'elle les diminue.

TABLE 3.5 – Résultat du modèle logit

| Variable | OR | IC 95% (bas) | IC 95% (haut) | p-value |
|---|---|---|---|---|
| const | 0,149 | 0,056 | 0,393 | 0,0001 |
| Asset management | 0,576 | 0,217 | 1,528 | 0,2677 |
| Commercial banking | 3,045 | 1,12 | 8,28 | 0,0291 |
| Corporate finance | 0,988 | 0,17 | 5,729 | 0,9894 |
| No business line | 2,267 | 0,826 | 6,22 | 0,1121 |
| Payment and settlement | 0,85 | 0,315 | 2,294 | 0,7479 |
| Retail banking | 16,127 | 6,068 | 42,865 | 0 |
| Retail brokerage | 2,323 | 0,148 | 36,404 | 0,5483 |
| Trading & sales | 0,404 | 0,142 | 1,147 | 0,0886 |
| log_loss | 1,448 | 1,392 | 1,506 | 0 |

*Source : Auteur, donnée de l'étude*

Le montant des pertes se montre fortement associé au caractère frauduleux d'un événement avec un odds ration d'environ 1,45 et une p-value inférieur à 0,001. Cela signifie que chaque unité supplémentaire du montant de perte transformé multiplie par 1,45 les chances qu'un événement soit classé comme fraude. Au niveau des ligne métier, la banque de détail a l'association la plus marquée. Elle a un odds ratios de 16,1, une p-value inférieur à 0,001. Par suite suivie par de la banque commerciale avec un un odds ratios de 3,05 et un p-value inférieur à 0,001. Par contre toutes les autres lignes métiers ne présentent pas d'effet statistiquement significatif au seuil de 5%.

### Qualité d'ajustement

Nous avons un pseudo $R^2$ de McFadden de 0,337 et un taux de prédictions correctes de 83% pour le modèle. Le test du rapport de vraisemblance confirme que l'ensemble des variables explicatives fournir une amélioration significative par rapport au modèle nulle avec un LN=1596,9 et une p-value inférieur à 0,001.

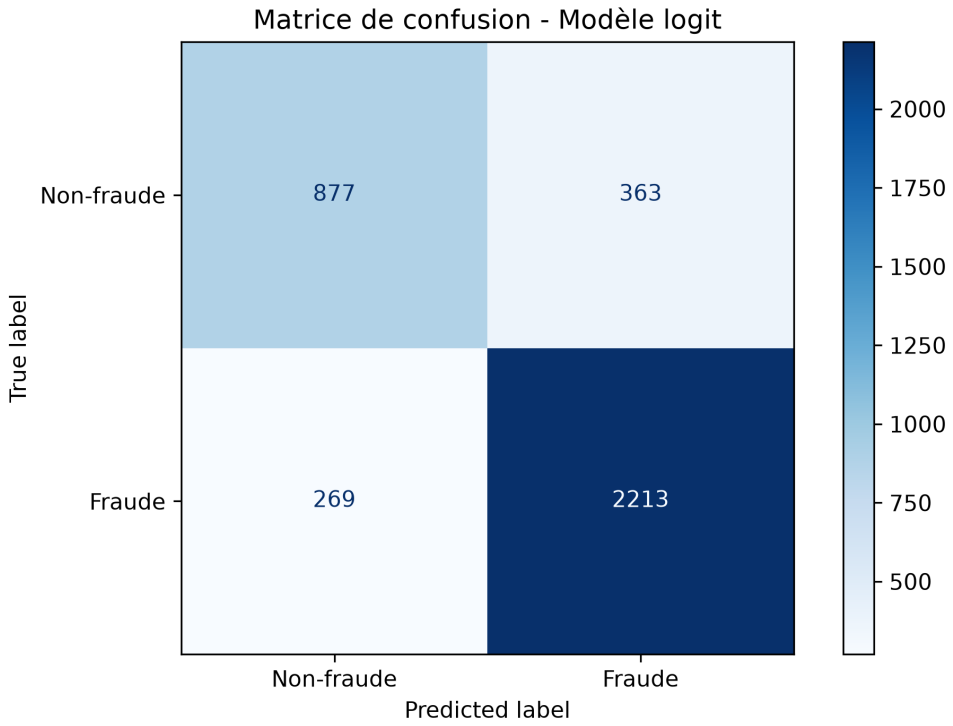



FIGURE 3.4 – Matrice de confusion du modèle logit

### Pouvoir discriminant

La capacité du modèle à distinguer les évènements de fraude des autres événements est bonne. La courbe ROC permet cette lecture, en faisant varier le seuil de décision plutôt qu'en se limitant au seuil unique de 0,5 pour le taux de prédictions correctes.

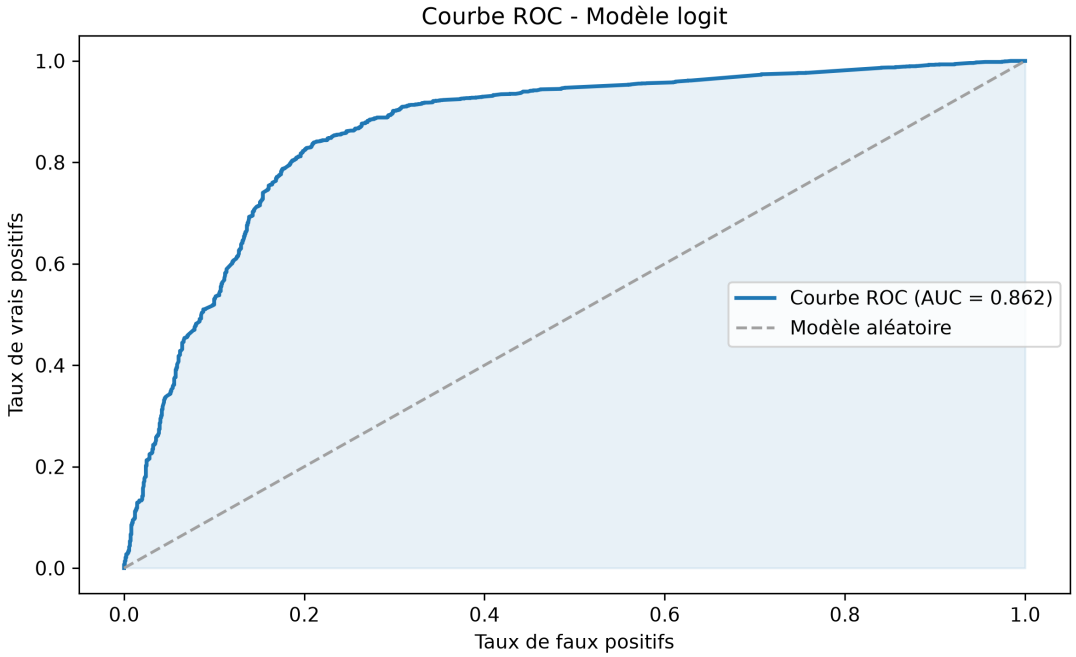



FIGURE 3.5 – Courbe ROC du modèle logit

### 3.2.4. Modèle Random Forest

Ce modèle est entrainé sur les mêmes variables explicatives que celle utiliser pour le logit. L'échantillon est découpé en sous-ensemble d'entrainement (2791 observations) et un sous ensemble de test (931 observations). Il est fait suivant une répartition stratifiée préservant la même proportion de fraude dans les deux. Les classes sont pondérées pour compenser le déséquilibre entre la catégorie Fraude et celle non-fraude. Le tableau 6 ci-dessous présentes les indicateurs de performance sur l'échantillon test.

TABLE 3.6 – Indicateurs de performance

| Variable | Importance |
|---|---|
| log_loss | 0,518869 |
| Business line_Retail banking | 0,195071 |
| Business line_Asset management | 0,168439 |
| Business line_Commercial banking | 0,047372 |
| Business line_Payment and settlement | 0,032558 |
| Business line_Trading & sales | 0,02479 |
| Business line_No business line | 0,012351 |
| Business line_Corporate finance | 0,000551 |
| Business line_Retail brokerage | 0 |

*Source : Auteur, donnée de l'étude*

Le modèle donne une accuracy de 83, 7% et une AUC de 0,867 sur l'échantillon test. Ces résultats sont légèrement meilleurs que celui du modèle logit. La précision et le rappel sont équilibrés entre les deux classes soit 0,88 pour la fraude. De ce fait, le modèle ne favorise pas une classe au détriment de l'autre malgré le déséquilibre initial.

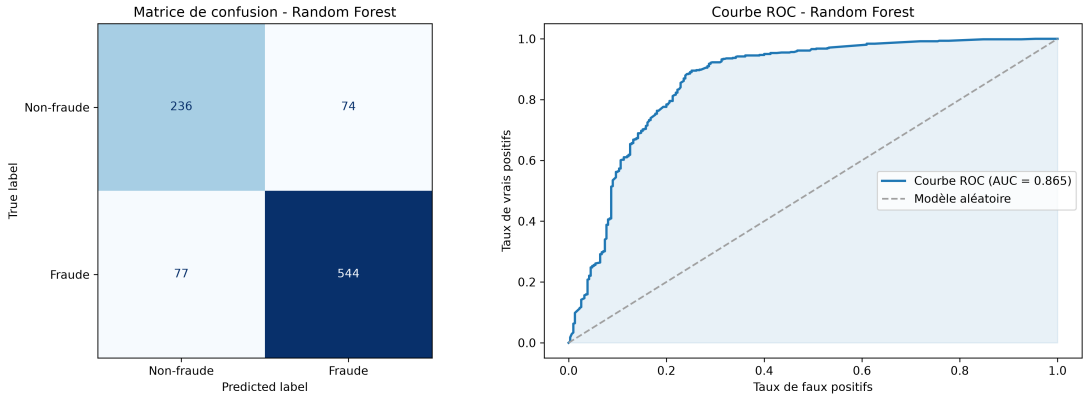



FIGURE 3.6 – Matrice de Confusion et Courbe ROC du modèle Random Fores

La figure 9 ci-dessous présentent l'importance relative de chaque variable dans les prédictions du modèle.

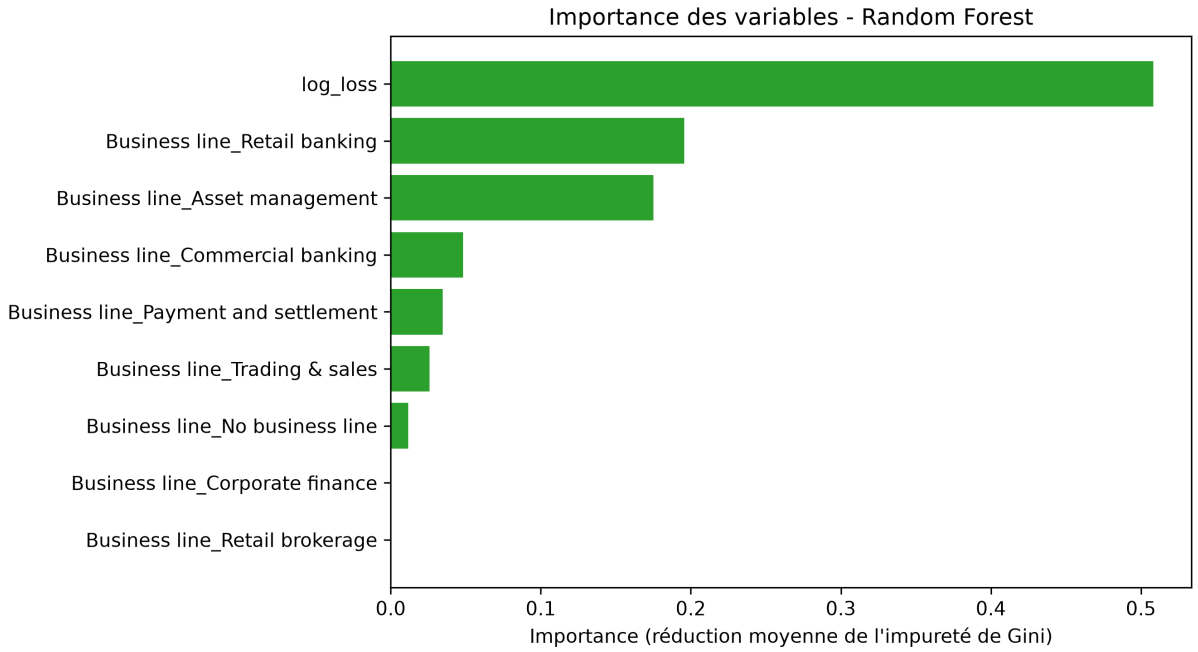



FIGURE 3.7 – Importance des varibables

Le montant de perte domine très largement l'importance des variables à $51,9\%$. Il est suivi par les lignes métier Retail Banking ($19,5\%$) et Asset management de ($16,8\%$). Ce classement recoupe les résultats du modèle logit et renforce donc la robustesse de ces deux facteurs comme déterminants du caractère frauduleux d'un événement. Par ailleurs, le Random forest améliore légèrement les performances par rapport au logit (accuracy et AUC supérieurs). Cependant, le logit garde l'avantage de donner une interprétation claire et chiffrée de chaque effet, alors que le Random Forest se contente de classer les variables par importance, sans dire si leur effet est positif ou négatif.

### 3.2.5. Modèle Gradient Boosting

Le Gradient Boosting est entrainé sur les mêmes variables explicatives et le même découpage (train / test) que les deux modèles précédents.il construit séquence par séquence les arbres et chaque nouvel corrige les erreurs des précédents. La performance prédictive sur l'échantillon test est présenté dans le tableau 9 ci-dessous.

TABLE 3.7 – Indicateurs de performance du modèle

| Classe / Métrique | Précision | Rappel | F1-score | Support |
|---|---|---|---|---|
| Non-fraude | 0,77 | 0,73 | 0,75 | 310 |
| Fraude | 0,87 | 0,89 | 0,88 | 621 |
| Macro avg | 0,82 | 0,81 | 0,81 | 931 |
| Weighted avg | 0,84 | 0,84 | 0,84 | 931 |
| Accuracy | | 0,8378 | | |

*Source : Auteur, données de l'étude*

De cette analyse, il en ressort que le modèle a les meilleures performances comparativement au deux précédents. Il obtient une accuracy de 83, 8% et une AUC de 0,87 légèrement au-dessus du Random Forets et du logit.

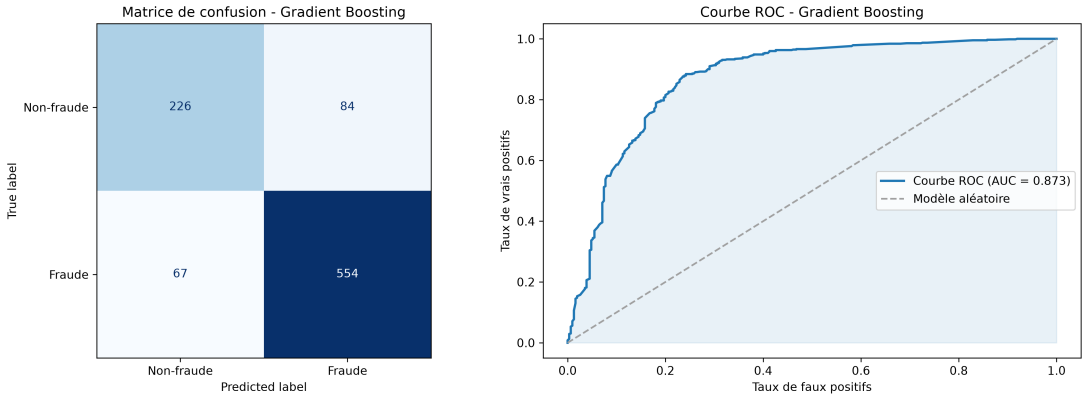



FIGURE 3.8 – Matrice de Confusion et Courbe ROC du modèle Gradient Boosting

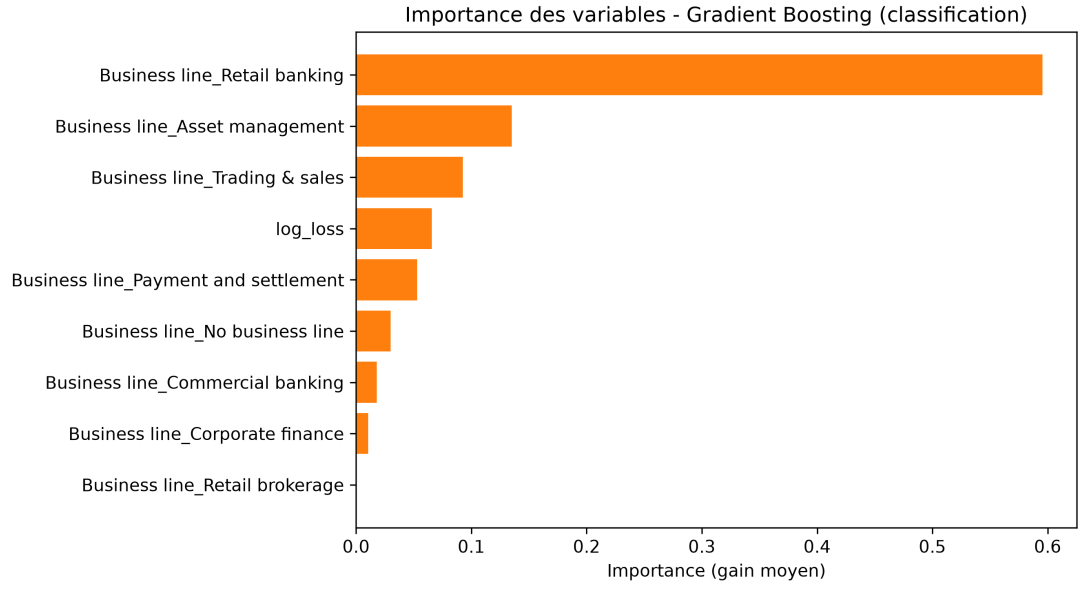



FIGURE 3.9 – Importance des variables

De plus, certaines variables se sont montrées très important lors de la classification.c'est la cas de la ligne métier Retail banking qui domine fortement avec $59,5\%$.Par suite, on a l'Asset Management qui vient avec $13,5\%$ . Ces résultats confirment les observations fait avec le logit et le Random Forest.

Quant à la modélisation de la sévérité, nous avons adopter l'architecture (fréquence/sévérité) annoncée plus haut. Un second modèle Gradient Boosting est entrainé pour prédire la distribution logarithmique des pertes en fonction des lignes métiers et type d'événement. Le tableau 3.8 résume les métriques de performance obtenues.

TABLE 3.8 – Indicateurs de performance de régression

| Métrique | Valeur |
|---|---|
| RMSE | 2,4548 |
| MAE | 1,8252 |
| $R^2$ | 0,4046 |

*Source : Auteur, données de l'étude*

Le modèle explique 40% de la variabilité de la sévérité tout en affichant une erreur absolue moyenne de 1,83 sur l'échelle logarithmique.

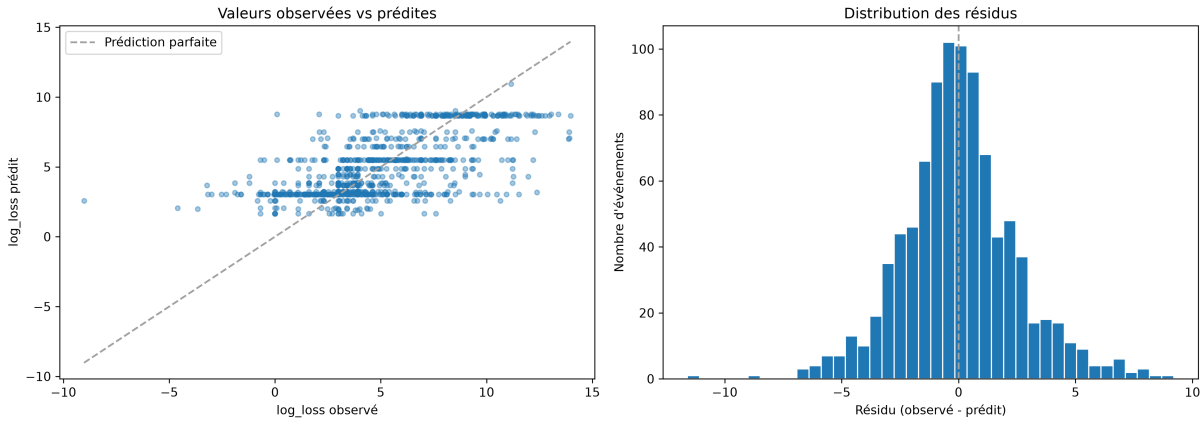



FIGURE 3.10 – Valeurs observées vs prédites et distributions des résidus

La figure 3.11 ci-dessous présentent l'importance relative de chaque variable dans les prédictions du modèle.

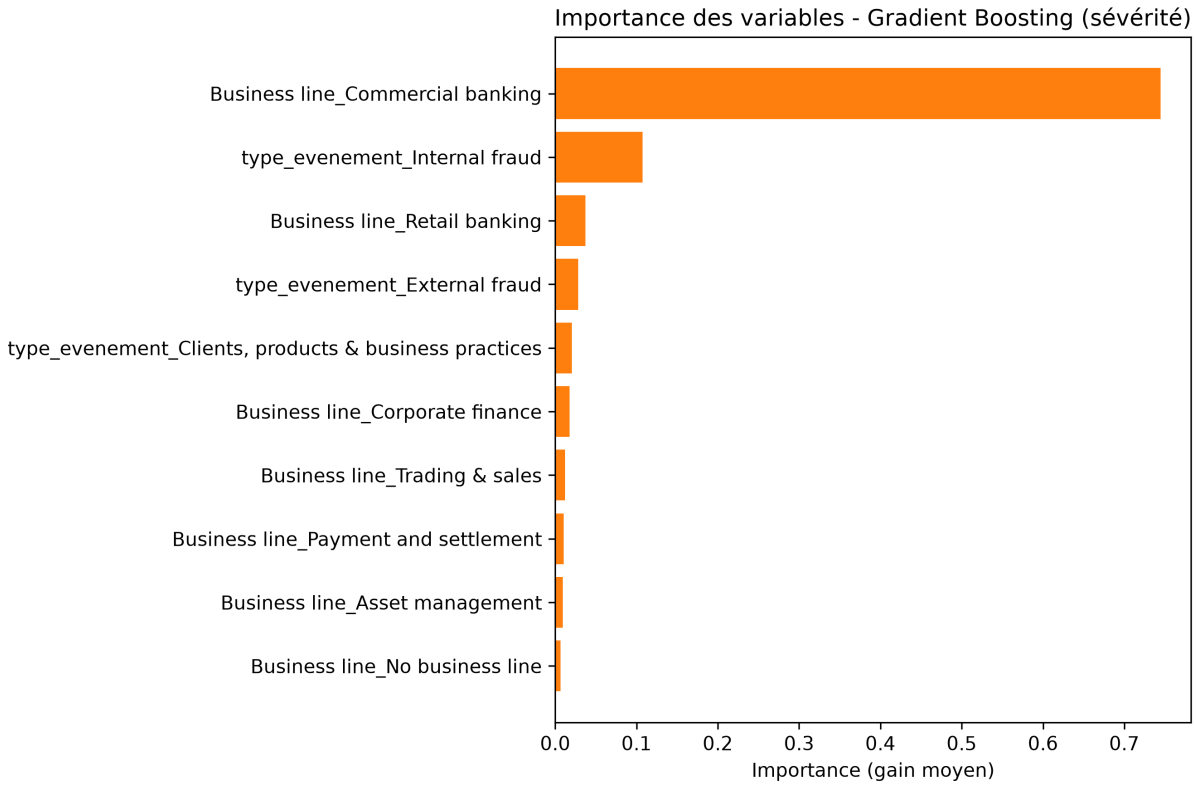



FIGURE 3.11 – l'importance relative de chaque variable

La ligne métier commercial banking domine l'importance des variables avec $74,5\%$. Par suite, on a Internal Fraud avec $10,7\%$. Cette observation s'explique par la gravité intrinsèque des sinistres associés. En effet, les 682 évènements recensés en banque commerciale (18% au total) enregistrent une charge moyenne de 8,40 contre 4,14 pour les autres lignes métiers. Le modèle capte ici un risque à faible récurrence mais à très fort enjeu financier.

### 3.2.6. Test de robustesse : contrôle du biais temporel et de la non stationnarité

L'analyse de stationnarité menée plus haut a révélé que la série de fréquence et celle de la sévérité sont non-stationnaire. Elle a révélé aussi un effet de troncature sur la période 2020-2022. Ainsi donc, il convient de s'assurer que les résultats des trois modèles ne reflètent pas simplement un effet de période masqué. Pour se faire, les trois modèles (logit, Random Forest,Gradient Boosting ) sont réestimé en intégrant une variable de contrôle temporelle, en plus des variables explicatives déjà retenues.

La variable de contrôle est construite par regroupement en décennie des années d'occurrence. Elle a été construite de cette façon pour ne pas imposer l'hypothèse de linéarité à l'effet de temps. Quant aux 65 événements sans année d'occurrence, ils sont conservés sous une modalité explicite Inconnue plutôt qu'exclus de l'analyses.

TABLE 3.9 – Comparaison des performances avec et sans variable de contrôle temporelle

| Modèle | Spécification | Accuracy | AUC / Pseudo $R^2$ | Significativité de la décennie |
|---|---|---|---|---|
| Logit | Sans décennie | 83,0% | 0,337 | — |
| Logit | Avec décennie | 84,6% | 0,364 | NSI, SC($p < 0,001$) |
| Random Forest | Sans décennie | 83,7% | 0,867 | — |
| Random Forest | Avec décennie | 85,7% | 0,898 | 4e variable la plus importante sur 14 |
| Gradient Boosting | Sans décennie | 83,8% | 0,873 | — |
| Gradient Boosting | Avec décennie | 85,4% | 0,899 | 7e variable la plus importante sur 14 |

*Source : Auteur, données de l'étude*

L'intégration de la nouvelle variable augmente la performance des trois modèles (gain d'accuracy de 1,6 à 2,0 points, gain d'AUC de 0,026 à 0,031). Ce résultat confirme qu'une partie de la variance non expliquée par les modèles de base était liée à l'absence de la période d'occurrence des événements.

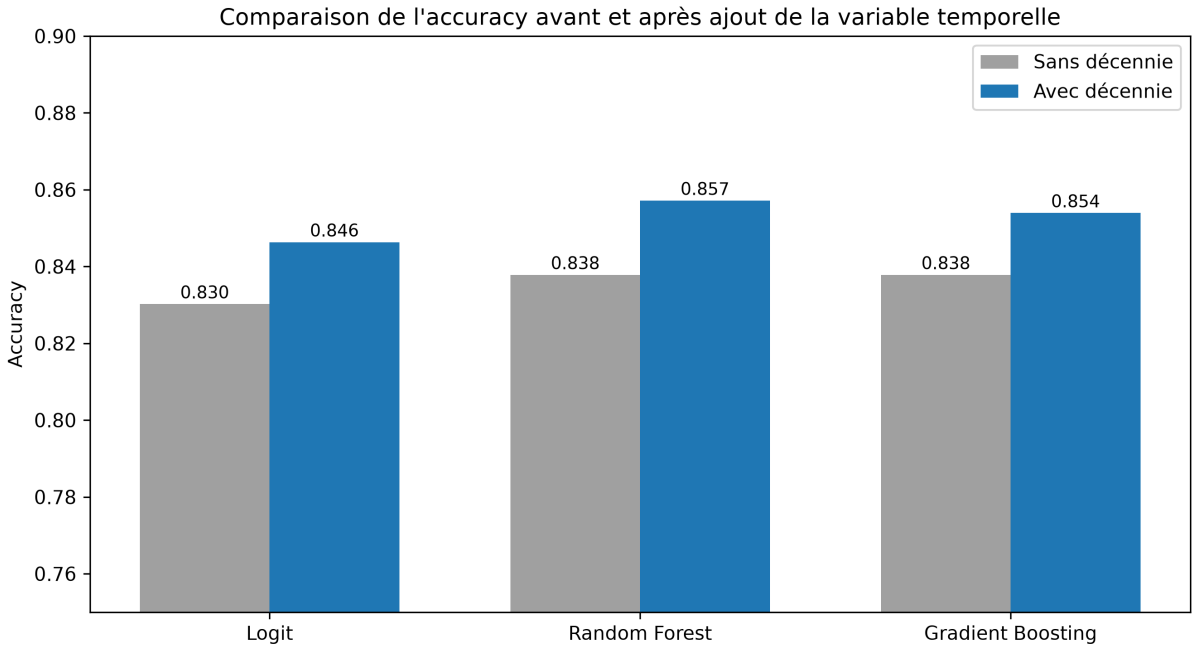



FIGURE 3.12 – comparaison de l'accuracy

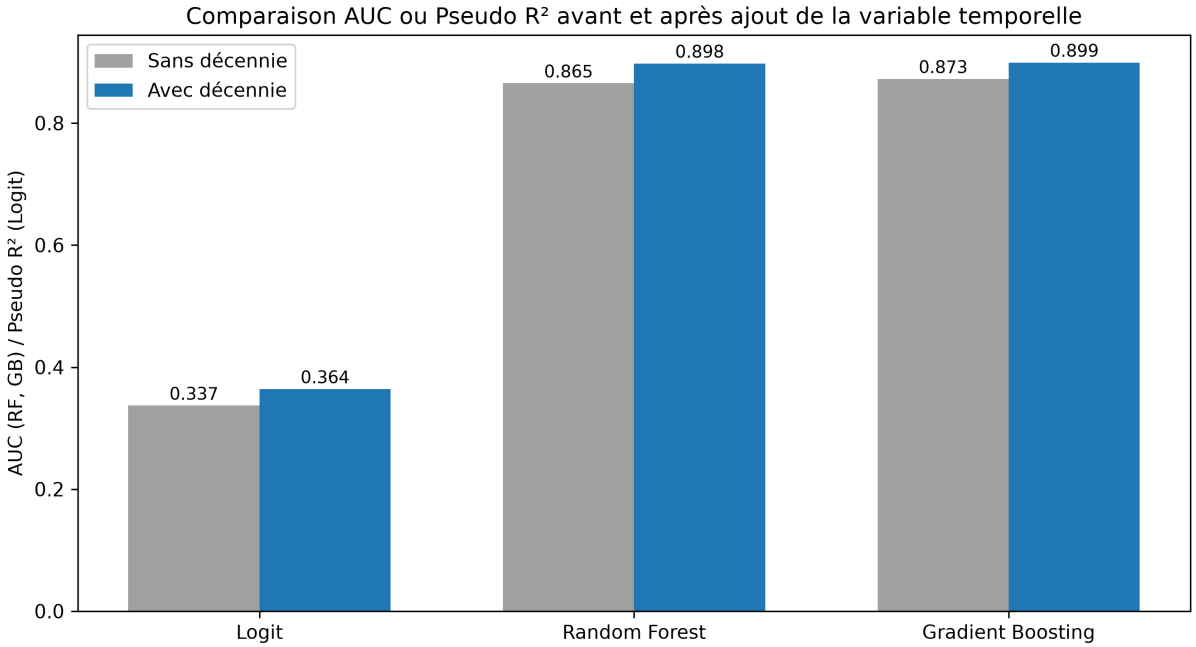



FIGURE 3.13 – comparaison AUC /Pseudo R2

Deux points méritent d'être soulignés. Premièrement, aucune décennie prise seule n'est significative à 5% pour le modèle logit. Autrement dire, l'effet du temps n'apparait que lorsqu'on regarde toutes les décennies ensemble. On a donc un effet diffus plutôt qu'une rupture nette à une période donnée. Deuxièmement, dans les modèles à base d'arbres, la variable temporelle reste secondaire dans classement d'importance. Elle est loin derrière la variable de perte logarithmique et la ligne métier Retail banking. Ces deux dernières variables restent donc les facteurs dominants. C'est résultat confirme la robustesse des conclusions principales.

### 3.2.7. Interprétabilité SHAP

Le SHAP est appliqué au modèle Gradient Boosting de classification pour avoir la contribution individuelle de chaque variable et vérifier la cohérence avec les résultats précédents.

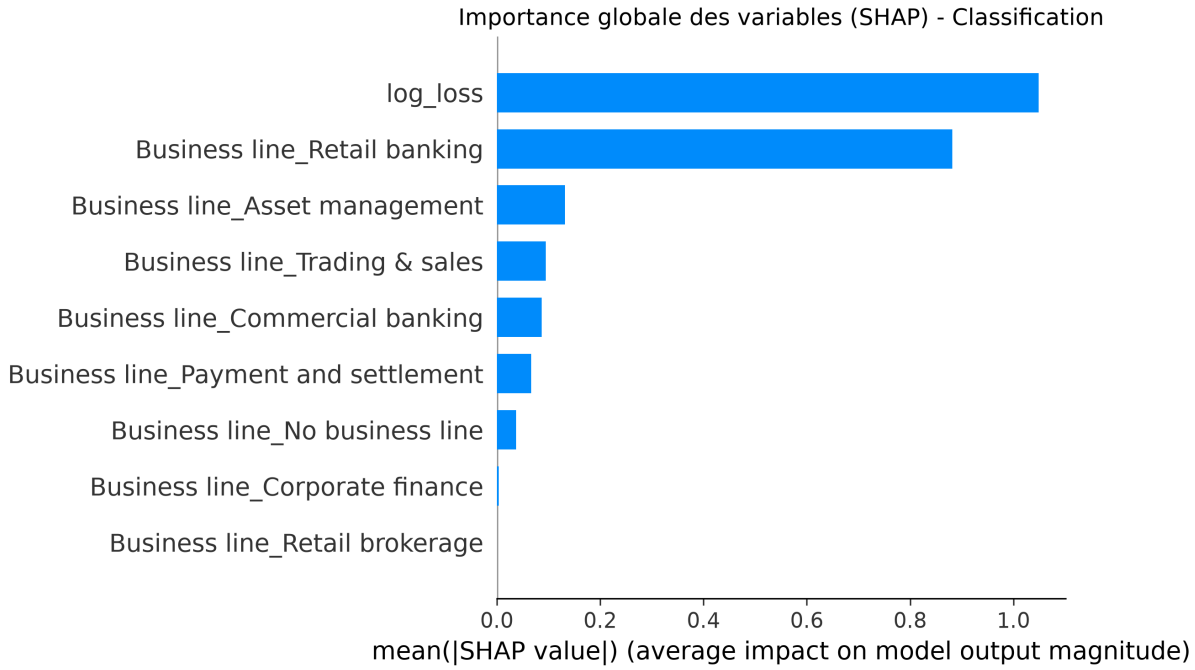



FIGURE 3.14 – Importance globale des variables (SHAP)

Les résultats confirment la dominance de la distribution des pertes logarithmique et la ligne metier Retail banking. Autrement dit, les résultats sont cohérent avec celui du logit,du Random Forest et de l'importance des variables du Gradient Boosting.

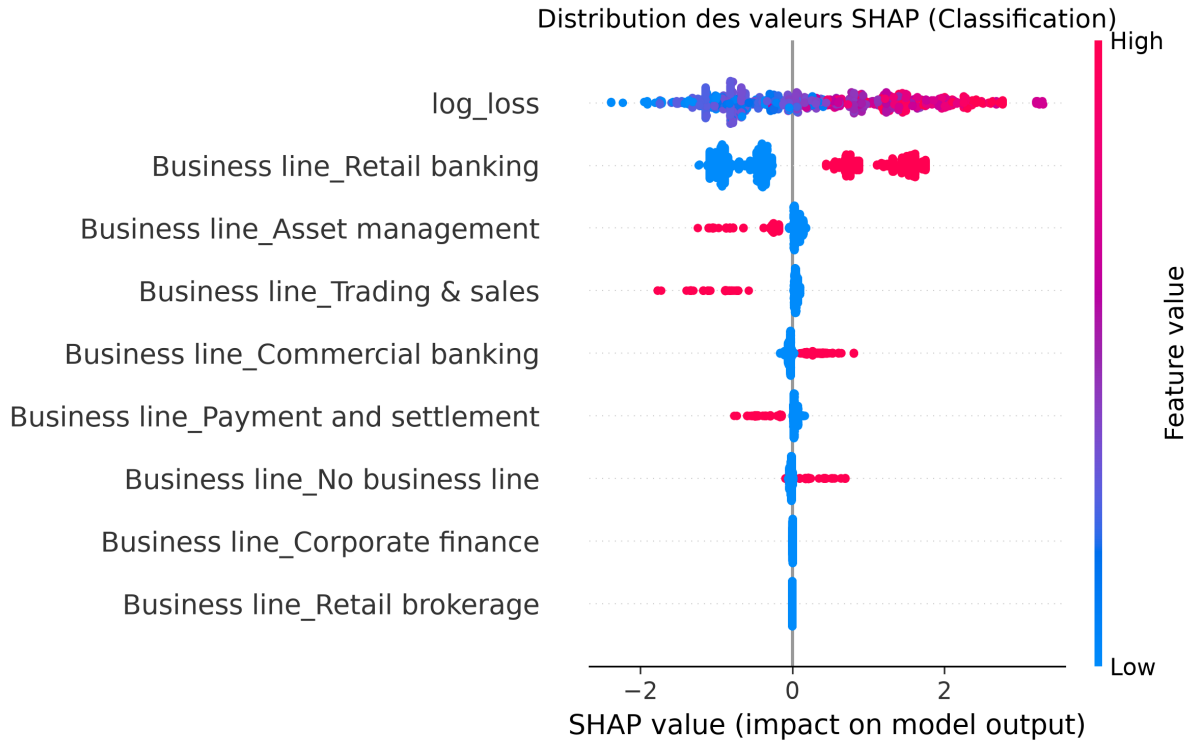



FIGURE 3.15 – Distribution des SHAP (Volet classification)

Le graphique de distribution permet de préciser le sens de ces effets. Les valeurs positives élevé de logloss sont associées à des valeurs de SHAP positive. Cette positivité, confirme qu'un montant de perte élevée accroit la probabilité qu'un évènement soit classé comme fraude.

Pour monter l'apport de SHAP en matière de justification individuelle des décisions, la figure 18 décompose la prédiction d'un événement particulier de l'échantillon test.

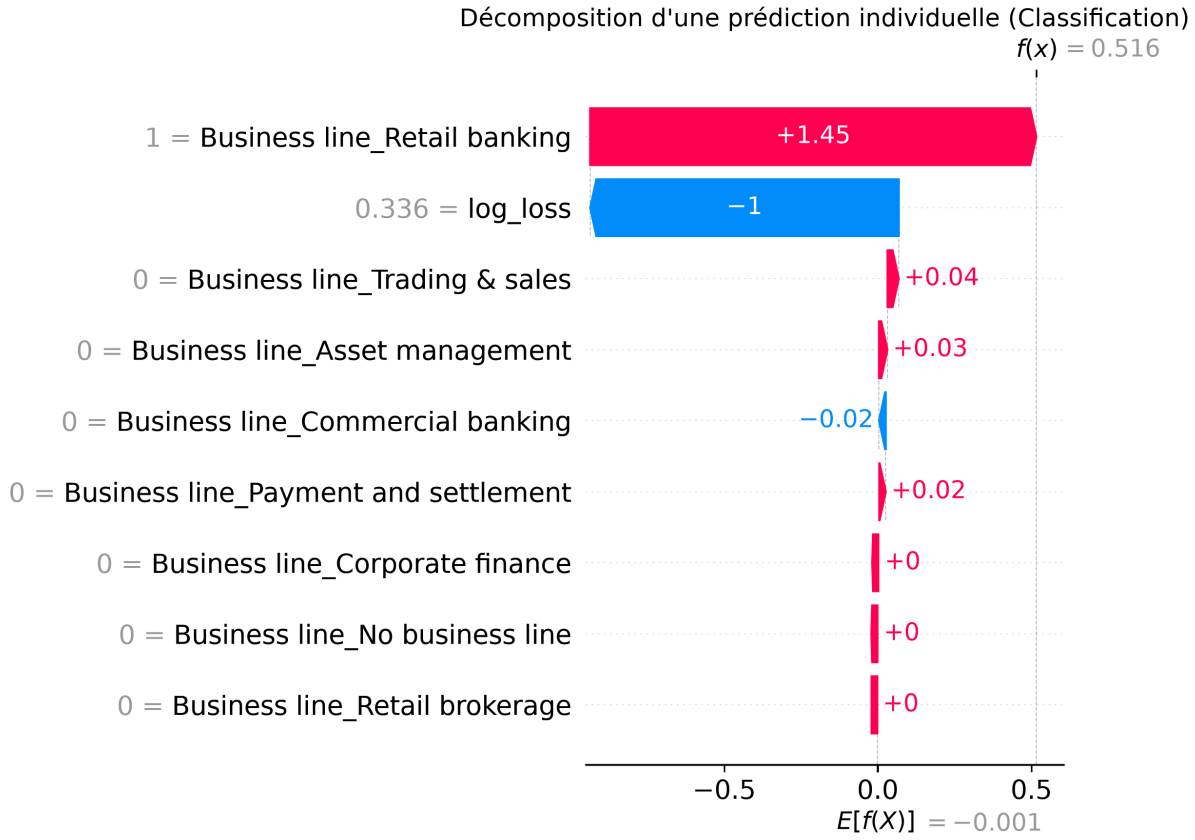



FIGURE 3.16 – Décomposition d'une prédiction individuelle

De cette décomposition, on voit variable par variable comment le modèle aboutit à sa prédiction finale à partir de la valeur de base. De plus, elle répond directement à l'exigence de justification documentée des décisions automatisées soulignée par Černevičienė et Kabašinskas (2024)

La même démarche est appliquée au modèle de sévérité.

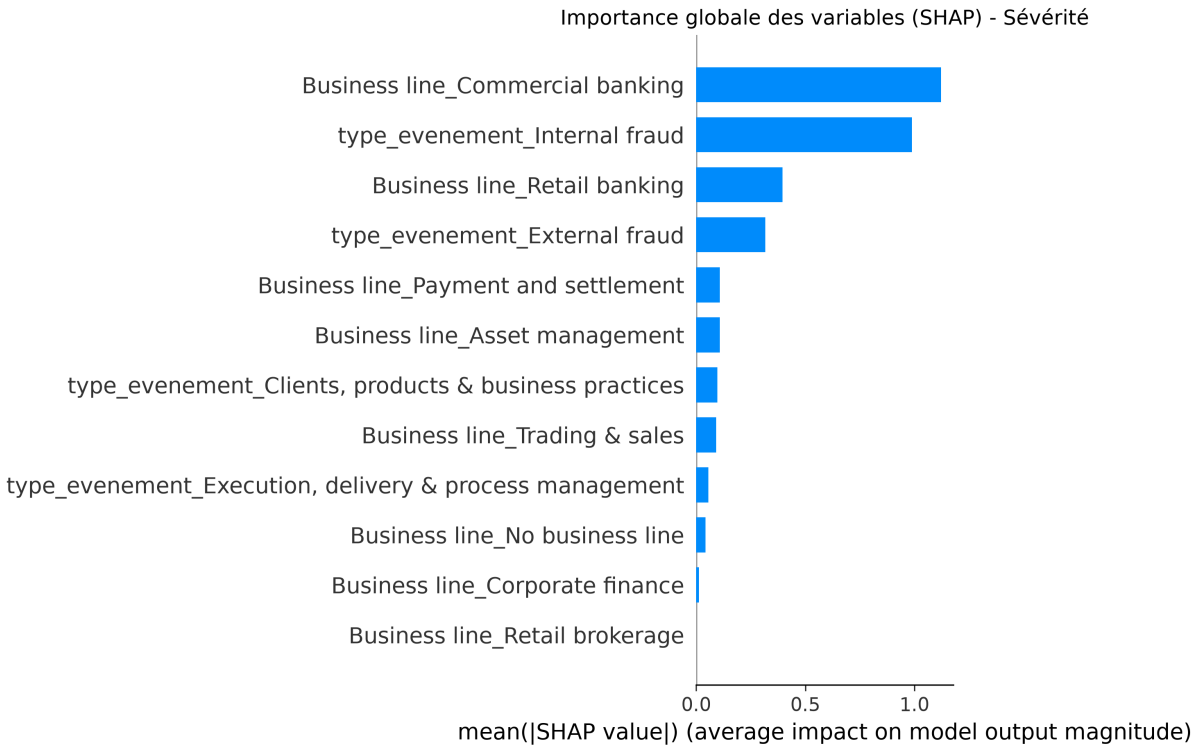



FIGURE 3.17 – Importance globale des variables SHAP (volet sévérité)

Ici, on voit clairement la prédominance de la ligne métier Commercial banking déjà identifiée par l'importance des variables classique, suivie du facteur Internal fraud dans le classement SHAP. Cette convergence entre les deux méthodes d'interprétation, indépendantes l'une de l'autres, renforce la robustesse de ce résultat.

# ★★★★★★★★ CHAPITRE 4 ★★★★★★★★
# DISCUSSION DES RÉSULTATS

## 4.1. SYNTHÈSE DES RÉSULTATS ET VALIDATION DES HYPOTHÈSES

### 4.1.1. Synthèse des résultats

Les performances des trois modèles se tiennent très proches les unes des autres dans un ordre croissant resté d'ailleurs relativement resserré. 83,0% d'accuracy au logit (pseudo $R^2$ de McFadden = 0,337), 83,% au Random Forest (AUC = 0,867), puis 83,8% au Gradient Boosting (AUC = 0,873). L'écart qui les sépare particulièrement à la seconde et la troisième position est si ténu qu'il pourrait amener à s'interroger sur la réelle plus-value qu'apporte la complexité supplémentaire de la construction séquentielle des arbres, donc la correction itérative des erreurs au regard du gain remporté.

Ce qui frappe davantage le regard est la constance des déterminants identifiés d'un modèle à l'autre .logloss et ligne métier Retail banking revenant systématiquement primés en tête au gré du logit du odds, du Random Forest du Gini ou du Gradient Boosting du gain moyen, le clignotant du point de vue des SHAP menés dans ce dernier modèle ne faisant qu'accompagner cette hiérarchie de davantage dans ses ressorts. L'appartenance à la banque de détail oriente presque toutes les prédictions vers la fraude alors que logloss éprouve d'avantage d'irrégularité sans direction unique. Le cas du volet sévérité livre un résultat contrasté. Le test de robustesse temporelle vient corroborer l'ensemble.Le gain d'accuracy ne fait pas beaucoup mieux (de 1,6 à 2,0 points) que l'on ne l'espérait (gain d'AUC de 0,026 à 0,031), et ne change pas l'ordre des déterminants principaux, encore largement dominés par logloss et Retail banking.

### 4.1.2. Validation des hypothèses

Les présentes analyses permettent de trancher sur les trois hypothèses de recherche.

**H1** établit que le montant de la perte et la ligne métier sont des variables déterminantes dans la fraude d'un événement. A ce sujet, elle est vérifiée sans ambiguïté.C'est la convergence des trois modèles sur ces deux variables, quel que soit le modèle d'estimation utilisé, qui le prouve.

**H2** établit qu'un modèle non linéaire de machine learning a plus de pouvoir prédictif qu'un modèle statistique traditionnel. Elle se vérifie également, mais avec moins d'ampleur qu'espéré.le gain est patent, mais mollissime, si bien qu'avec un écart quasi nul entre la Random Forest et le Gradient Boosting, il apparaît que l'essentiel de la relation entre les variables disponibles et la fraude est déjà capté par un modèle simple.

**H3** prédit que l'explicabilité SHAP permet de réconcilier la performance d'un modèle peu lisible et l'attente réglementaire d'une justification documentée. Elle est aussi au titre d'une vérification. SHAP ne va pas cependant valider une hiérarchie de variables dont on avait déjà l'importance.SHAP en explicite le sens et permet de décomposer chacune en un apport exploitable à mobiliser pour justifier une alerte auprès d'une équipe de conformité.

## 4.2. SUGGESTIONS

Trois pistes se dégagent naturellement de ces résultats.

Quant au premier sujet abordé, il demeure que le développement des variables explicatives s'articule autour de deux ou trois variables catégorielles seulement, ce qui limite mécaniquement l'apport prédictif du modèle notamment dans le domaine de la sévérité où le $R^2$ de 0,40 laisse encore une part significative de variance non expliquée. À cet égard, faire appel à des variables textuelles, par exemple en considérant la description de l'incident par NLP, ou à des variables contextuelles d'ordre macro-financier, pourrait atténuer une part de cette perte.

La seconde voie consiste à envisager dans le détail l'inscription opérationnelle du modèle. Loin de se réduire à un outil de scoring en temps réel, où SHAP jouerait un rôle fondamental pour tracer chaque alerte au sein des équipes de conformité, elle serait susceptible de donner un prolongement concret à ce travail faisant écho à la nécessaire justification des décisions automatisées, inscrite au cœur de la problématique réglementaire, au principe du modèle.

Finalement, le test de robustesse temporelle pourrait être plus poussé. Plutôt qu'un simple test par décade, opter pour une modélisation explicite de la troncature post-2019 via une correction de type Heckman ou par pondération inverse de la probabilité de déclaration, par exemple permettrait de mieux converger vers un effet significatif du temps, plutôt qu'un artefact de collecte de la donnée.

## 4.3. LES LIMITES

Trois limites principales viennent tempérer ces résultats.

La première renvoie à l'éventuelle troncature de la base sur la période post-2019, sans doute liée à la temporalité entre la survenance d'un incident et sa déclaration effective : les conclusions portant sur les années les plus récentes de l'échantillon doivent donc être prises avec précaution, difficulté d'extrapolation expresse.

La deuxième limite tient au nombre réduit de variables conservées. L'abandon de Causal factor, nécessaire pour juguler la fuite de données repérée en amont, a réduit mécaniquement

le pouvoir explicatif disponible lacune d'autant plus difficile à défendre sur la dimension sévérité, si compliquée à évaluer, tant pour le construire que pour la contrer.

La troisième limite s'avère cette fois-ci contextuelle. En effet, la base P-COLD ne couvre que le secteur bancaire chinois entre 1986 et 2023. Or, malgré son émanation académique et son contrôle par des experts de l'établissement, rien ne garantie que ces résultats puissent être étendus à d'autres systèmes bancaires, et donc au moins ceux des pays occidentaux, soumis à des normes réglementaires et des configurations de marché très différentes. Cette question ne peut qu'ouvrir la voie, ici encore, à un travail de validation externe.

# CONCLUSION GÉNÉRALE

Ce mémoire s'est élaboré au départ d'un constat simple posé dès la revue de littérature, le risque opérationnel est, des grands risques bancaires, celui pour lequel la modélisation peine le plus à trouver sa place entre un cadre réglementaire qui a sacrifié au souci de se montrer sensible au risque réel, la simplicité (la SMA), d'une part, et un machine learning, par ailleurs, encore dispersé en applications sporadiques et rarement conçues comme un véritable dispositif de pilotage. Ainsi la question ayant guidé l'intégralité de ce travail.Comment articuler la rigueur de la modélisation statistique traditionnelle avec les capacités prédictives du machine learning, sans perdre en chemin l'explicabilité qu'exigent aujourd'hui les superviseurs ?

La voie d'exploration empirique poursuivie sur la base P-COLD apporte à cette question une réponse plus nuancée qu'on ne l'aurait peut-être souhaité. Les trois modèles logit, Random Forest, Gradient Boosting s'accordent sur l'essentiel.Le montant de la perte et l'appartenance à la banque de détail ressortent dans les trois cas comme les déterminants principaux du caractère frauduleux d'un événement. Et c'est bien cette convergence plus que la performance brute de tel ou tel modèle qui constitue le résultat le plus robuste de ce mémoire. Elle ne dépend pas de la méthode d'estimation retenue, ce qui éloigne l'idée d'un simple artefact propre à un algorithme bien particulier. Le gain de pouvoir prédictif apporté par le machine learning existe bien mais demeure modeste face au logit, ce qui invite à nuancer l'enthousiasme parfois exagéré réservé à la seule complexité algorithmique.

Ce travail n'est pas pour autant sans limites, et il serait malhonnête de les passer sous silence. La base présente une troncature apparente sur sa période la plus récente, le nombre de variables explicatives disponibles reste restreint après l'exclusion nécessaire de Causal factor, et l'ancrage géographique unique au système bancaire chinois invite à la prudence quant à toute généralisation. Ces limites ne referment pas le sujet, elles ouvrent plutôt des pistes, enrichir les variables par des données textuelles ou macro-financières, transposer le modèle en un véritable outil de scoring où SHAP jouerait un rôle central de documentation des alertes, ou encore valider ces résultats sur d'autres bases bancaires, occidentales notamment.

Au fond, ce que montre ce mémoire, c'est qu'il n'y a pas lieu d'opposer rigueur statistique et machine learning dans la gestion du risque opérationnel. Les deux se combinent, se valident mutuellement par leur convergence, et surtout se complètent.Le premier pour la solidité inférentielle, le second pour la flexibilité prédictive, l'interprétabilité SHAP formant le pont qui permet de tenir les deux ensemble sans jamais perdre de vue les exigences de gouvernance propres au secteur bancaire.

# RÉFÉRENCES

[Basel Committee on Banking Supervision, 2005] Basel Committee on Banking Supervision (2005). International convergence of capital measurement and capital standards : A revised framework. Technical report, Bank for International Settlements.

[Briceño, 2025] Briceño, O. (2025). Standardised measurement approach (sma) versus advanced measurement approaches (ama) : A critical review of approaches in operational risk. Technical report, National University of San Marcos, Lima, Pérou.

[Chernobai et al., 2007] Chernobai, A. S., Rachev, S. T., and Fabozzi, F. J. (2007). *Operational Risk : A Guide to Basel II Capital Requirements, Models, and Analysis*. John Wiley & Sons, Hoboken.

[De Fontnouvelle et al., 2006] De Fontnouvelle, P., DeJesus-Rueff, V., Jordan, J. S., and Rosengren, E. S. (2006). Capital and risk : New evidence on implications of large operational losses. *Journal of Money, Credit and Banking*, 38(7) :1819–1846.

[Frachot et al., 2001] Frachot, A., Georges, P., and Roncalli, T. (2001). Loss distribution approach for operational risk. Technical report, Groupe de Recherche Opérationnelle, Crédit Lyonnais, France.

[George et al., 2025] George, M. Z. H., Alam, M. K., and Hasan, M. T. (2025). Machine learning for fraud detection in digital banking : A systematic literature review. In *World Conference on Scientific Discovery and Innovation*, pages 37–61.

[Heß and Damásio, 2025] Heß, V. L. and Damásio, B. (2025). Machine learning in banking risk management : Mapping a decade of evolution. *International Journal of Information Management Data Insights*, 5(1) :100324.

[Leo et al., 2019] Leo, M., Sharma, S., and Maddulety, K. (2019). Machine learning in banking risk management : A literature review. *Risks*, 7(1) :29.

[Nouy, 2006] Nouy, D. (2006). Le champ du risque opérationnel dans bâle ii et au-delà. *Revue d'économie financière*, (84) :11–24.

[ORX, 2020] ORX (2020). Cause and impact operational risk reference taxonomy. Technical report, ORX (Operational Riskdata eXchange Association).

[Pakhchanyan, 2016] Pakhchanyan, S. (2016). Operational risk management in financial institutions : A literature review. *International Journal of Financial Studies*, 4(4) :1–21.

[Sanford and Moosa, 2015] Sanford, A. D. and Moosa, I. A. (2015). Operational risk modelling and organizational learning in structured finance operations : A bayesian network approach. *Journal of the Operational Research Society*, 66(1) :86–115.

[Thirlwell, 2010] Thirlwell, J. (2010). Basel iii and operational risk : The missing piece ? *FS Focus, Financial Services*.

[Thirlwell, 2011] Thirlwell, J. (2011). Operational risk : Cinderella or prince charming ? *Chartered Banker*.

[Zhu et al., 2024] Zhu, X., Chang, Y., and Li, J. (2024). A cross-institutional database of operational risk external loss events in Chinese banking sector 1986–2023. *Scientific Data*, 11 :939.

[Černevičienė and Kabašinskas, 2024] Černevičienė, J. and Kabašinskas, A. (2024). Explainable artificial intelligence (xai) in finance : A systematic literature review. *Artificial Intelligence Review*, 57 :216.

## A. STATISTIQUES DESCRIPTIVES

TABLE 4.1 – Statistiques descriptives du montant des pertes (en 10 000 CNY)

| Statistique | Valeur |
|---|---|
| Nombre d'observations ($N$) | 3 722 |
| Moyenne | 28 490,6 |
| Médiane | 70,0 |
| Écart-type | 704 236,2 |
| Minimum | 0,000005 |
| Maximum | 41 000 000 |
| Asymétrie (skewness) | 53,8 |
| Aplatissement (kurtosis) | 3 087,4 |
| 1er quartile ($Q_1$) | 20,0 |
| 3e quartile ($Q_3$) | 1 212,4 |
| 90e centile | 13 000,0 |
| 95e centile | 40 000,0 |
| 99e centile | 274 232,0 |

*Source : Auteur, données P-COLD*

## B. TEST DE STATIONNARITÉ

TABLE 4.2 – Résultats du test ADF sur les séries annuelles (1999-2019)

| Série | Stat. ADF | $p$-value | Lags | Conclusion (5%) |
|---|---|---|---|---|
| Fréquence annuelle | -0,301 | 0,925 | 6 | Non stationnaire |
| Fréquence annuelle, diff. 1re | -3,772 | 0,003 | 5 | Stationnaire |
| Perte totale annuelle | -3,452 | 0,009 | 0 | Stationnaire |
| Log(perte totale annuelle) | -3,010 | 0,034 | 0 | Stationnaire |

*Source : Auteur, données P-COLD*

## C. DICTIONNAIRE DES VARIABLES

TABLE 4.3 – Dictionnaire des variables de la base P-COLD

| N° | Champ | Description |
|---|---|---|
| 1 | Event ID | Identifiant unique de l'événement |
| 2 | Start year | Année de début de l'événement |
| 3 | Start month | Mois de début de l'événement |
| 4 | End year | Année de fin de l'événement |
| 5 | End month | Mois de fin de l'événement |
| 6 | Loss amount | Montant réel de la perte (unité : 10 000 CNY) |
| 7 | Province occurred | Province, région autonome, municipalité ou région administrative spéciale où l'événement s'est produit |
| 8 | City occurred | Ville où l'événement s'est produit |
| 9 | Bank involved code | Banque concernée, représentée par un code anonymisé |
| 10 | Causal factor | Cause de l'événement : personnes, processus, systèmes ou événements externes |
| 11 | Event type | Catégorie d'événement selon la typologie en 7 classes du Comité de Bâle |
| 12 | Business line | Ligne métier selon la typologie en 8 classes du Comité de Bâle |

*Source : Auteur, data dictionary P-COLD*

## D. RÉPARTITION DES ÉVÉNEMENTS PAR CATÉGORIE ET LIGNE MÉTIER

TABLE 4.4 – Répartition croisée des événements par type de risque et ligne métier ($N = 3\,723$)

| Type d'événement | Agenc | Gest. actifs | Banq. comm. | Fin. entr. | Sans ligne | Paieme | Banq. détail | Court. dé-tail | Marcl | Total |
|---|---|---|---|---|---|---|---|---|---|---|
| Interruption & pannes systèmes | 1 | 3 | 0 | 0 | 2 | 3 | 23 | 0 | 1 | 33 |
| Clients, produits & activité comm. | 6 | 235 | 35 | 1 | 8 | 118 | 60 | 1 | 80 | 544 |
| Dommages aux biens | 0 | 4 | 0 | 0 | 25 | 0 | 2 | 0 | 0 | 31 |
| Emploi & sécurité au travail | 0 | 0 | 0 | 0 | 19 | 2 | 4 | 0 | 0 | 25 |
| Exécution, livraison & processus | 8 | 356 | 46 | 2 | 22 | 64 | 99 | 0 | 11 | 608 |
| Fraude externe | 1 | 14 | 241 | 4 | 3 | 61 | 777 | 0 | 8 | 1 109 |
| Fraude interne | 7 | 213 | 360 | 3 | 138 | 101 | 511 | 2 | 38 | 1 373 |
| **Total** | **23** | **825** | **682** | **10** | **217** | **349** | **1 476** | **3** | **138** | **3 723** |

*Source : Auteur, données P-COLD*

# TABLE DES MATIÈRES

**AVERTISSEMENT** i

**CERTIFICATION** ii

**DÉDICACES** iii

**REMERCIEMENTS** iv

**SIGLES ET ABRÉVIATIONS** v

**Sommaire** vi

**LISTE DES FIGURES** viii

**LISTE DES TABLEAUX** ix

**RÉSUMÉ** x

**ABSTRACT** xi

**INTRODUCTION GÉNÉRALE** 1

0.0.1 Contexte . . . 1
0.0.2 Problématique . . . 1
0.0.3 Intérêt de l'étude . . . 2
0.0.4 Objectifs et hypothèses . . . 2
0.0.5 Organisation du travail . . . 3

**1 CADRE THÉORIQUE DE L'ÉTUDE** 4

1.1 Revue de littérature . . . 4
1.1.1 Le risque opérationnel (définitions et Importances) . . . 4
1.1.2 Les différentes catégories du risque opérationnel. . . . 6
1.1.3 Évolution des méthodes de mesure de risques opérationnels de Bâle 6
1.1.4 Data analytics et machine learning appliqués au risque . . . 8
1.1.5 Positionnement de la recherche . . . 10

**2 CADRE MÉTHODOLOGIQUE DE L'ÉTUDE** 11

2.1 Population d'étude et sources des données . . . 11
2.1.1 Population d'étude . . . 11
2.1.2 Source des données . . . 11
2.1.3 Apurement et prétraitement des données . . . 12
2.1.4 Présentation des variables de l'étude . . . 13

2.2 Construction des pertes logarithmique . . . . . 13
2.3 Analyse exploratoire et tests statistiques préalables . . . . . 14
2.3.1 Analyse descriptive . . . . . 14
2.3.2 Analyse de stationnarité et tests statistiques . . . . . 14
2.3.3 Modèle de régression logistique multinomiale et son estimation . . 14
2.3.4 Modèle Random Forest . . . . . 16
2.3.5 Modèle Gradient Boosting . . . . . 16
2.3.6 La méthode SHAP . . . . . 18

**3 PRÉSENTATION DES RÉSULTATS 19**
3.1 Apurement et prétraitement des données . . . . . 19
3.2 Analyse exploratoire et tests statistiques préalables . . . . . 19
3.2.1 Analyse descriptive . . . . . 19
3.2.2 Analyse de la stationnarité et tests statistiques . . . . . 21
3.2.3 Modèle de régression logistique multinomiale et son estimation . . 22
3.2.4 Modèle Random Forest . . . . . 26
3.2.5 Modèle Gradient Boosting . . . . . 27
3.2.6 Test de robustesse : contrôle du biais temporel et de la non stationnarité 30
3.2.7 Interprétabilité SHAP . . . . . 32

**4 DISCUSSION DES RÉSULTATS 36**
4.1 Synthèse des résultats et validation des hypothèses . . . . . 36
4.1.1 Synthèse des résultats . . . . . 36
4.1.2 Validation des hypothèses . . . . . 36
4.2 suggestions . . . . . 37
4.3 Les limites . . . . . 37

**CONCLUSION GÉNÉRALE 39**

**Références 39**

**Annexes A**

**Table des matières D**